

공 학 석 사 학 위 논 문

기계학습 기법을 이용한 운동 상상
뇌파 분류 연구

2025년 2월

국립부경대학교 대학원

데이터공학과

고승혁

공 학 석 사 학 위 논 문

기계학습 기법을 이용한 운동 상상
뇌파 분류 연구

지도교수 김 훈 희

이 논문을 공학석사 학위논문으로 제출함.

2025년 2월

국 립 부 경 대 학 교 대 학 원

데 이 터 공 학 과

고 승 혁

고승혁의 공학석사 학위논문을 인준함.

2025년 2월 21일

위 원 장
위 원
위 원

공학박사
공학박사
공학박사

장 원 두 (인)
김 훈 희 (인)
유 승 호 (인)



목 차

| | |
|---|-----|
| 표목차 | ii |
| 그림목차 | iii |
| 논문요약 | v |
| I. 서 론 | 1 |
| II. 연구 방법 | 4 |
| 1. 데이터셋 | 7 |
| 2. 전처리 과정 | 12 |
| 3. 분류 모델 | 27 |
| 2.3.1 FLDA | 27 |
| 2.3.2 SVM | 29 |
| 2.3.3 SGD | 31 |
| 2.3.4 MLP | 32 |
| III. 연구 결과 | 34 |
| 1. 특징 추출 형태 | 35 |
| 2. 피험자별(trial data) 성능 평가 | 39 |
| 3.2.1 Common Spatial Pattern(CSP) 적용 결과 | 40 |
| 3.2.2 Wavelet Transform 적용 결과 | 56 |
| 3. 특징 추출기, 모델 조합에 따른 성능 평가 | 72 |
| IV. 토의 | 75 |
| 1. 결론 | 75 |
| 2. 연구의 한계점 | 77 |
| 참고문헌 | 78 |

표 목 차

| | |
|--|----|
| [Table. 1] Experiment Participant Information | 10 |
| [Table. 2] CSP based Data Features Shape | 36 |
| [Table. 3] Wavelet Transform based Data Features Shape | 38 |
| [Table. 4] Subject Data Accuracy, f1-score with CSP, Multi Classification Model | 73 |
| [Table. 5] Subject Data Accuracy, f1-score with CSP, Multi Classification Model | 74 |

그 립 목 차

| | |
|---|----|
| [Fig. 1] Brain-computer Interface(BCI) | 3 |
| [Fig. 2] research work process | 4 |
| [Fig. 3] EEG Experiment Measurement Section | 8 |
| [Fig. 4] Experimental one trial process | 9 |
| [Fig. 5] Left, Right hand screen type | 9 |
| [Fig. 6] Preprocessing process | 12 |
| [Fig. 7] EEG Data Signal | 14 |
| [Fig. 8] EEG Data Signal after Butterworth, band-pass Filtering | 14 |
| [Fig. 9] Butterworth Filtering | 14 |
| [Fig. 10] Band-pass Filtering | 16 |
| [Fig. 11] High-Pass Filtering | 18 |
| [Fig. 12] EMG Data Signal | 19 |
| [Fig. 13] EMG Data Signal after Butterworth, High-Pass Filtering | 19 |
| [Fig. 14] Common Average Reference(CAR), Band-Pass Filtering Results of EMG Signal | 21 |
| [Fig. 15] Hilbert Transform Magnitudes of EMG Signals | 22 |
| [Fig. 16] Common Spatial Patterns based Data Features | 35 |
| [Fig. 17] Wavelet Transform based Data Features | 37 |
| [Fig. 18] Confusion Matrix of individual dataset with CSP, FLDA | 43 |
| [Fig. 19] Confusion Matrix of individual dataset with CSP, SVM | 47 |
| [Fig. 20] Confusion Matrix of individual dataset with CSP, SGD | 51 |
| [Fig. 21] Confusion Matrix of individual dataset with CSP, MLP | 55 |

그 립 목 차

| | |
|--|----|
| [Fig. 22] Confusion Matrix of individual dataset with Wavelet Transform, FLDA | 59 |
| [Fig. 23] Confusion Matrix of individual dataset with Wavelet Transform, SVM | 63 |
| [Fig. 24] Confusion Matrix of individual dataset with Wavelet Transform, SGD | 67 |
| [Fig. 25] Confusion Matrix of individual dataset with Wavelet Transform, MLP | 71 |

기계학습 기법을 이용한 운동 상상 뇌파 분류 연구

고 승 혁

국립부경대학교 대학원 데이터공학과

요 약

본 논문은 실제 뇌파 장비로 측정된 데이터를 바탕으로 인공지능 기법을 활용하여 행동을 구별한 연구이다. 연구에서는 EEG 데이터를 사용하였으며, 뇌파 측정 시스템인 BCI2000을 활용하여 데이터를 수집하였다. 총 68개의 채널(64개의 EEG 채널과 4개의 EMG 채널)을 측정하였다.

피험자는 총 52명의 건강한 성인으로 구성되었으며, 각 피험자는 뇌파 측정기를 통해 64개의 EEG 채널 데이터를 기록하였다. 동시에 피험자의 손과 팔에서 4개의 EMG 채널 데이터를 측정하여 총 68개의 채널 데이터를 확보하였다. 뇌파 측정 과정은 피험자 앞 화면에 제시된 4가지 시각 자극을 통해 진행되었다. 각 자극은 3초 동안 제시되었으며, 실험은 Rest, Motor imagery, Rest 순서로 진행되었다. 한 번의 실험(trial)은 총 7초로 설정되었고, 각 피험자는 100~120회의 trial을 수행하였다. 실험 전, 실험 중, 실험 종료 후에는 설문조사를 통해 피험자의 상태를 확인하였다.

수집된 데이터 중 52명의 피험자 중 19명의 뇌파 데이터를 선별하여 분석에 사용하였다. 선별된 데이터를 기반으로 뇌파 상태를 분류하였으며, CSP(Common Spatial Patterns)를 사용해 특징을 추출한 후 모델에 적용하였다. 뇌파 상태 분류에는 Fisher's Linear Discriminant Analysis(FLDA)를 활용하였다. FLDA는 두 클래스 간 데이터 분포를 최적화하여 분류 성능을 높이는 차원 축소 기법이다. 64개의 EEG 채널 데이터를 모두 사용한 FLDA 분류 결과, 평균 정확도는 51.35%로 나타났다.

추가적으로, Wavelet Transform과 Support Vector Machine(SVM), Stochastic Gradient Descent(SGD), Multi-Layer Perceptron(MLP)을 적용하여 다양한 결과를 확인하였다. Wavelet Transform을 통해 각 뇌파 채널의 특징을 추출하였고, SVM은 두 클래스 간 경계를 정의하기 위해 마진을 최대화하는 초평면을 찾아 데이터를 분류하였다. 그 외에도 SGD, MLP를 사용하여 데이터를 분류하였다. 제안된 방법을 통해 적용 결과를 분석한 결과, 뇌파와 같은 시계열 데이터가 머신러닝 기법을 통해 효과적으로 분류될 수 있음을 확인하였다. 또한, 단일 모델이 아닌 다양한 모델을 적용함으로써 데이터의 성능을 비교하고 분석할 수 있었다.

Classification of Motor Imagery EEG using Machine Learning

Seung Hyuk Ko

Department of Data Engineering, The Graduate School,
Pukyong National University

Abstract

This paper is a study that uses artificial intelligence techniques to distinguish behaviors based on data measured by actual EEG equipment. EEG data was used in this study, and the data was collected using BCI2000, an EEG measurement system. A total of 68 channels (64 EEG channels and 4 EMG channels) were measured.

The subjects consisted of 52 healthy adults, each of whom had 64 channels of EEG data recorded by the EEG machine. At the same time, four EMG channels were measured from the subjects' hands and arms, totaling 68 channels of data. The EEG measurement process was conducted through four visual stimuli presented on a screen in front of the subject. Each stimulus was presented for 3 seconds, and the trials were presented in the following order: Rest, Motor imagery, Rest. Each trial was set to a total duration of 7 seconds, and each subject performed 100-120 trials. Before, during, and after the experiment, the subjects were surveyed to check their condition.

From the collected data, EEG data of 19 out of 52 subjects were selected and used for analysis. Based on the selected data, EEG states were classified, and features were extracted using Common Spatial Patterns (CSP) and applied to the model. Fisher's Linear Discriminant Analysis (FLDA) was used to classify EEG states. FLDA is a dimensionality reduction technique that improves classification performance by optimizing the distribution of data between two classes. FLDA classification using all 64 EEG channels showed an average accuracy of 51.35%.

In addition, we applied the Wavelet Transform, Support Vector Machine (SVM), Stochastic Gradient Descent (SGD), and Multi-Layer Perceptron (MLP) to see different results. Wavelet Transform was used to extract the features of each EEG channel, and SVM was used to classify the data by finding the hyperplane that maximizes the margin to define the boundary between two classes. In addition, SGD and MLP were used to classify the data. By analyzing the results of the proposed method, we found that time series data such as EEG can be effectively classified using machine learning techniques. In addition, by applying various models rather than a single model, we were able to compare and analyze the performance of the data.

I. 서론

최근 머신러닝과 관련된 연구는 활발하게 이루어지고 있다. 머신러닝은 인공지능(AI)의 분야 중 하나로, 컴퓨터가 명시적으로 프로그래밍되지 않고 데이터를 학습하여 패턴을 인식하고 결정을 내릴 수 있도록 하는 기술이다. 이 기술은 대량의 데이터를 분석하고, 그 데이터를 바탕으로 미래의 상황을 예측하거나 분류 작업을 수행하는 데 사용된다.

머신러닝 분야는 감정 구별 및 행동 구별에서도 활용된다. 해당 분야에서는 뇌-컴퓨터 인터페이스(BCI, Brain-Computer Interface)라는 뇌파 등 생체신호를 활용하여 행동이나 상태를 구별하는 데 주로 사용된다. 이러한 기능에서는 각 피험자가 주관적인 형식으로 데이터가 나타나기 때문에, 생체신호를 측정하여 문제를 해결한다.

생체신호는 신체에서 발생하는 다양한 전기적, 화학적, 물리적 활동을 나타내는 신호로, 주로 생체 시스템의 기능적 상태를 반영한다. 이러한 신호는 신경계, 심혈관계, 근육계, 호흡계 등 다양한 생리적 시스템에서 발생하며, 의료 및 과학적 연구에서 중요한 역할을 한다.

대표적인 생체신호는 electroencephalography (EEG), galvanic skin response(GSR), electrocardiography (ECG), electromyography (EMG) 등이 대표적이다. 그중에서 EEG를 활용한 연구는 Brain-Computer Interface(BCI) 분야에서 진행하고 있다. [1, 2]

BCI는 인간의 뇌와 외부 장치 간의 직접적인 소통을 가능하게 하는 시스템으로, 전통적인 신경 또는 근육 경로를 거치지 않고도 뇌의 신호를 사용하여 장치를 제어할 수 있는 기술이다. [4] BCI를 활용하여 측정된 뇌파를 컴퓨터 통해서 입력받은 후 제어 명령어를 통해 로봇, 드론 등 사물 제어를 할 수 있는 기술을 의미한다(Fig. 1).

이러한 생체신호 관련 연구는 영상 시청, 음악 감상 등과 같이 인간의 육감을 다루는 연구에서도 진행되었다. [3] 또 다른 연구에서는 Motor Imagery(MI)라는 것을 사용하는 방법이 존재한다. [8] MI는 실제로 피험자가 주어진 자극에 대해서 보여지는 뇌파 상태를 보여줄 수 있다고 말할 수가 있다.

이와 관련하여 생체신호를 측정하는 방법은 다양하게 있으며, 그중에서

BCI2000이라는 것이 존재한다. BCI2000은 뇌파를 측정하는 시스템 중 하나로, 뇌파 측정뿐만 아니라, 다양한 모듈로 구성된 오픈 소스이다. [2,17] 또한 생체신호를 측정하는 장비 중에서는 The Biosemi ActiveTwo System이라는 것도 존재한다. [18] 이 시스템은 뇌파를 측정하는 시스템으로, 다채널, 고해상도 생체전위 측정을 할 수 있으며, EEG, ECG, EMG 등의 신호를 기록하는 데 사용한다. 다만, 생체신호를 측정 과정에서는 노이즈 등이 발생하기가 쉽다. 노이즈를 제거하기 위해 본 연구에서는 필터링을 사용하였다. 뇌파는 시간 기반 신호 형태이기 때문에 신호의 필터링 방법을 사용하여 노이즈를 제거하는 방법이 있다. [10-12]

BCI2000과 같이 측정 시스템을 사용해 뇌파를 측정하여 생체 데이터를 다루는 사례가 있다. 대표적으로 머신러닝을 적용한 사례가 있다. 4가지의 손가락 움직임을 화면에서 실시간으로 보여주어, 주어진 시간 내 뇌파를 측정하여 측정한 뇌파를 바탕으로 Fisher's linear discriminant analysis(FLDA)를 사용하여 73.08의 Accuracy를 달성하였다. [1] 이와 비슷한 방법으로 노이즈를 사용하여 각 피험자의 예측하는 방법이 존재한다. [8-10] 또한 수집한 뇌파를 사용하여 전처리 과정을 통해 Wavelet Transform과 같이 각 데이터의 특징을 추출하여 K-means를 사용하여 클러스터를 수행한 후 Feed Forward Neural Network를 사용하여 83.1의 Accuracy를 달성하였다. [14] 또한 Spatial filter를 사용하여 각 데이터의 특징을 최적화하여 Linear Discriminants Analysis(LDA)에 적용한 결과 89.40의 Accuracy를 달성하였다. [15] 그 외에도 Deep convolutional neural networks(DCNN)와 같이 Deep Neural Network를 사용하여 90%의 정확도를 달성하였다. [16] 그런데, k-means에서는 뇌파 데이터와 같이 비선형 데이터의 경우에는 선형적으로 분리하는 것에 한계점이 존재한다. 또한 비선형 데이터의 특성상 linear discriminants analysis는 선형 데이터에서는 분류를 잘 수행한다. 이와 반대로, 뇌파와 같은 비선형 데이터에서는 각 데이터의 패턴을 학습하는 데에는 어려움이 존재한다. 또한, DCNN과 같이 CNN의 경우에는 대규모의 데이터가 필요하기 때문에, 뇌파 데이터가 충분히 모으지 못한 경우에는 Accuracy 면에서 성능이 좋을지라도, 과적합과 같은 문제점이 나올 수 있으며, 또한 충분히 학습되었는지는 알 수가 없다는 점이 존재한다. 즉, 비선형 데이터에서 특징을 추출하는 방법과 모델에

따라서 성능이 달라질 수 있는 것을 알 수 있다.

본 연구에서는 The Biosemi ActiveTwo System, BCI2000을 사용하여 측정된 뇌파 데이터를 사용하여 머신러닝을 사용하여 각 행동의 상태를 구별하는 것을 구현하였다. The Biosemi ActiveTwo System, BCI2000을 사용하여 각 피험자의 뇌파 데이터를 수집하고, 머신러닝 모델에 적용시키기 전에 수집한 뇌파 데이터에서 전처리 과정을 수행했다. 이를 통해 데이터 내 노이즈를 제거하고, 데이터가 잘 측정이 되어있는지 확인했다. 그 후에 모델에 적용하기 전에 데이터를 분류하여 올바르게 측정된 데이터를 수집하였다. 이후 수집한 데이터를 바탕으로 머신러닝 모델에 적용했다. 이를 위해 Common Spatial Patterns(CSP), Wavelet Transform을 사용하여 각 피험자의 뇌파 데이터에서 데이터의 특성을 추출했다. 그 후에 데이터의 특성을 바탕으로 Fisher's Linear Discriminants Analysis(FLDA), Support Vector Machine(SVM), Stochastic Gradient Descent(SGD), Multi-Layer Perceptron(MLP)을 사용했다. 이를 통해 각각의 Accuracy, f1-score를 출력하여 각 성능을 확인했다.

본 논문에서는 다음과 같이 구성한다. 제2장에서는 데이터셋, 실험 방법에 대해 살펴본다. 제3장에서는 실험 결과를 살펴본다. 제4장에서는 실험에 대한 결론, 시사점, 한계점을 제시한다.




Fig 1. Brain-computer Interface (BCI)

II. 연구 방법

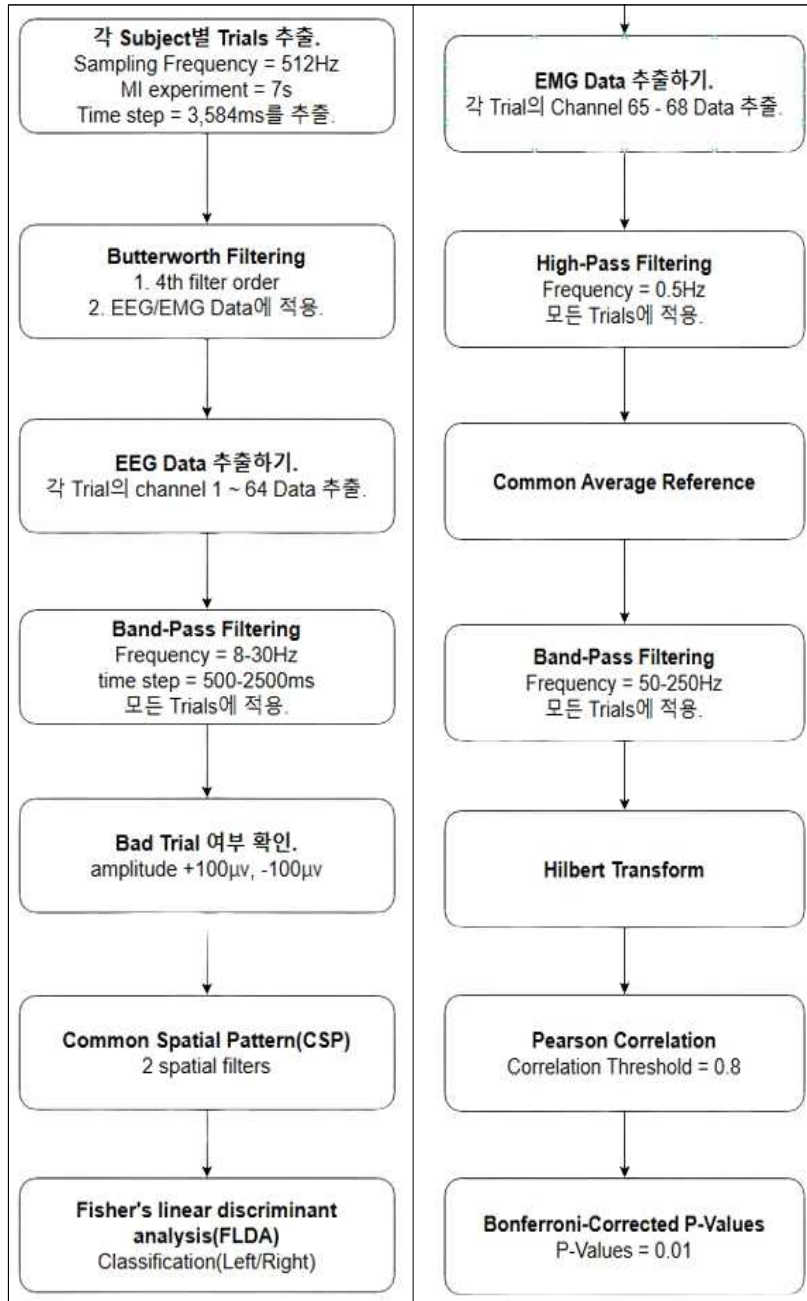


Fig 2. research work process

본 장에서는 구현한 연구의 전체적인 흐름을 소개한다(Fig. 2). BCI2000을 기반으로 각 피험자의 데이터를 수집하고, 피험자별로 Trials 데이터를 추출했다. 이때, Sampling Frequency는 512Hz, Time Step은 3,584ms로 설정하여 Trial 데이터로 추출했으며, 각 피험자마다 Trial Data 개수는 Motor Imagery Left Data 100 또는 120개, Imagery Right Data 100 또는 120개, Movement Data 20개의 Trial Data를 추출했다.

전처리를 수행하기 전에 Butterworth Filtering을 수행했다. 이때, 차수(order) 값을 4로 설정하였으며, Trial Data에 대해서 적용했다. 이를 통해 뇌파 데이터에 있는 측정된 노이즈를 제거했다. 이후 Trial Data에 대해서 EEG/EMG Data를 분류했다. 이때 Channel 1~64를 EEG Data, 65~68을 EMG Data로 분류했다. 이 과정에서 Imagery data는 EEG Data, Movement data는 EMG Data를 추출했다.

분류된 EEG Data는 bad trial 여부를 확인하였다. 이를 위해서 band-pass filtering을 수행하여 정해진 주파수에 대한 신호를 통과하였다. 주파수 범위를 8-30Hz로 설정하여 Motor Imagery(MI)와 관련된 주파수를 강조하고, 신호 내에 있는 노이즈를 제거했다. 그 후에 신호의 진폭(Amplitude)를 $\pm 100 \mu V$ 로 설정하여 EEG Data의 품질을 검토하였으며, 진폭 값이 $\pm 100 \mu V$ 를 초과하는 Trial 데이터는 bad trial로 분류하여 제외하였다. 본 연구에서는 각 피험자의 EEG Data를 모두 적용시켜 확인된 bad trial를 제외하였다.

EMG Data에서도 bad trial 여부를 확인하였다. 이를 위해서, high-pass filtering을 사용하여 주파수를 0.5Hz로 설정하여, EMG 내 신호에 있는 노이즈를 제거하고, 이후 Common Average Reference(CAR)를 적용하였다. 이후 band-pass filtering을 50-250Hz를 설정하여 EMG와 관련된 대역을 강조하고, 신호 내에 있는 저주파 및 고주파 노이즈를 제거했다. 그 이후 Hilbert Transform을 수행하여 EMG 신호에 있는 진폭을 추출한 후, Pearson Correlation과 Bonferroni-Corrected P-value를 각각 0.8, 0.01로 설정하여 bad trial 여부를 판별했다.

다음으로, bad trial를 제외한 EEG Data를 사용하여 분류 적용하기 위해 특징 추출 단계를 수행하였다. Common Spatial Pattern과 Wavelet Transform을 활용하여 EEG 데이터의 특징을 추출하였다. 추출한 특징 데

이터를 바탕으로 분류 모델에 적용하였으며, 사용한 분류 모델은 Fisher's Linear Discriminant Analysis(FLDA), Support Vector Machine(SVM), Stochastic Gradient Descent(SGD), Multi-Layer Perceptron(MLP)이다. 각 모델에 적용한 결과를 바탕으로 분류 성능을 확인했다.

II-1 데이터셋

본 연구에서는 EEG 데이터셋을 활용하여 손잡이 분류 기능을 구현하였다. 데이터셋은 52명의 피험자로부터 측정된 뇌파 데이터로 구성되었으며, 피험자는 왼손잡이와 오른손잡이로 구분되었다. 피험자 중 19명은 여성이었으며, 모든 피험자는 건강한 상태였다(Table 1).

데이터는 The Biosemi ActiveTwo System, BCI2000 system 3.0.2를 사용하여 뇌파를 측정하여 수집하였다. 측정된 채널은 다음과 같다(Fig. 3). 측정된 데이터는 총 68개의 신호로 구성되어 있다. 측정된 신호는 512Hz의 주기(Sampling Rate)로 수집이 되었으며, 각 뇌파와 EMG를 동시에 측정하였다. 각 신호는 64개의 뇌파와 4개의 EMG로 구성되어 있다.

실험은 피험자 앞에 스크린을 설치한 상태에서 진행되었다. 스크린에는 처음 2초 동안 흑색 화면이 나타났으며, 이후 3초 동안 손 모양이 표시되었다. 여기서, 보여주는 손 모양은 왼쪽 손, 오른쪽 손 중 하나로, 각 손은 4개의 형태 중 랜덤으로 보여줬다(Fig 5). 그 후에 2초 동안의 휴식(Rest) 구간을 제공했다. 그 이후 과정은 이전과 동일한 방식으로 진행했으며, 한번의 측정 과정은 20회 반복했다(Fig 4).

1번 실험 후에는 피험자 설문조사를 진행하여 피험자의 실험 만족도와 몸 상태, 시험 지속 가능성을 확인하였다.

본 실험을 통해 수집된 데이터셋은 다음과 같다. 각 피험자에서 Imagery Left Data, Imagery Right Data, Movement Left Data, Movement Right Data를 수집했다. 각 데이터는 68개의 채널로 구성되어 있으며, 각 샘플은 Imagery Data는 358,400 또는 430,080으로 구성되어 있었고, Movement Data는 71,680으로 구성되었다. 각 채널에 대해서는 다음과 같이 구성되어 있다(Fig. 3). 위치에 있는 각 전극에 대한 신호 값으로 구성되었다. 또한, 각 데이터에서는 1~64가 EEG Channel, 65~68은 EMG Channel로 구성되어 있으며, 각 채널에 대한 측정값이 데이터로 구성되어 있다.

수집된 데이터는 EEG와 EMG 데이터로 나뉘며, Imagery Data, Movement Data를 Trial 데이터로 분류하였다. Sampling Rate는 512Hz로 설정되었으며, Imagery Data는 100 또는 120개의 Trial로, Movement Data는 20개의 Trial로 추출했다.




Fig 4. Experimental one trial process [1]




Fig 5. Left, Right hand screen type [1]

Table 1. Experiment Participant Information

| Sample ID | Handedness | Age | Sex |
|-----------|------------|-----|--------|
| s1 | Right | 24 | Female |
| s2 | Right | 29 | Male |
| s3 | Right | 23 | Female |
| s4 | Right | 31 | Male |
| s5 | Right | 20 | Male |
| s6 | Right | 27 | Male |
| s7 | Right | 26 | Male |
| s8 | Right | 20 | Male |
| s9 | Right | 24 | Male |
| s10 | Right | 18 | Male |
| s11 | Right | 21 | Male |
| s12 | Right | 25 | Female |
| s13 | Right | 26 | Female |
| s14 | Right | 27 | Female |
| s15 | Right | 25 | Female |
| s16 | Right | 28 | Male |
| s17 | Right | 27 | Female |
| s18 | Right | 29 | Male |
| s19 | Right | 24 | Male |
| s20 | Both | 32 | Female |
| s21 | Right | 20 | Male |
| s22 | Right | 19 | Male |
| s23 | Right | 19 | Male |
| s24 | Right | 25 | Male |
| s25 | Right | 25 | Female |
| s26 | Right | 26 | Male |
| s27 | Right | 33 | Male |
| s28 | Right | 19 | Male |
| s29 | Right | 20 | Male |
| s30 | Right | 29 | Male |
| s31 | Right | 28 | Male |
| s32 | Right | 23 | Female |
| s33 | Both | 29 | Female |
| s34 | Right | 27 | Male |
| s35 | Right | 30 | Male |
| s36 | Right | 25 | Male |
| s37 | Right | 26 | Female |

| Sample ID | Handedness | Age | Sex |
|-----------|------------|-----|--------|
| s38 | Right | 26 | Male |
| s39 | Right | 23 | Female |
| s40 | Right | 28 | Female |
| s41 | Right | 23 | Female |
| s42 | Right | 30 | Male |
| s43 | Right | 20 | Female |
| s44 | Right | 19 | Male |
| s45 | Right | 19 | Male |
| s46 | Right | 19 | Male |
| s47 | Right | 23 | Female |
| s48 | Right | 26 | Female |
| s49 | Right | 28 | Female |
| s50 | Right | 24 | Male |
| s51 | Right | 28 | Male |
| s52 | Right | 25 | Male |

II-2 전처리 과정

수집된 신호는 인공지능 모델에 적합하도록 전처리 과정을 거쳤다. 뇌파와 같은 시계열 데이터는 피험자의 상태에 따라 다르게 측정되기 때문에 잡음이 포함될 가능성이 높다. 이를 고려하여 본 연구에서는 전처리 과정으로 Butterworth Filtering, High-pass Filtering, Band-pass Filtering, Common average reference, Hilbert Transform, Pearson correlation, Bonferroni-corrected P-value, Common Spatial Pattern(CSP), Wavelet Transform을 사용하였다. 잡음을 제거하기 위해 Butterworth, frequency-pass filtering, CAR(Common average reference) 기법을 사용하였으며, EEG, EMG 데이터에 모두 적용하였다(Fig 6).




Fig 6. Preprocessing process

신호의 전처리 과정은 총 5단계로 구성된다. 첫 번째 단계는 Trial 데이터 분리(Trial Data Separation)이다. 측정된 데이터는 II-1에서 사용한 2가지 장비를 사용하여 수집된 뇌파 데이터로, 뇌파 데이터를 Trial 기준으로 데이터를 분류했다. 뇌파 데이터는 샘플링 비율(Sampling rate)을 512Hz, 1번 trial을 7s로 수행했다. 이것을 기준으로 수집된 데이터는 3,584($512 * 7$) 샘플로 구성된 trial data로 나누었다. Fig. 7에서는 이와 같이 나눈 Trial Data 중 하나를 볼 수가 있었다. 이를 통해서 실험을 수행한 7s 동안 측정된 뇌파 신호를 확인해볼 수 있었다.

두 번째 단계는 나쁜 trial 검사(Bad Trial percentage)이다. 이는 수집한 뇌파 data 중 노이즈가 심하거나, 측정이 잘못된 데이터를 식별하기 위한 과정이다. Bad Trial 데이터는 분류 모델의 성능에 부정적인 영향을 미치므로 이를 제외하였다. 이를 위해 각 데이터에 있는 EEG/EMG Data를 따로 분리하고, 별도의 전처리 방식을 사용하여 bad trial 검사를 수행했다.

이렇게 분리된 EEG/EMG Data는 Butterworth Filtering을 수행했다. Butterworth Filtering은 신호 처리에서 사용되는 아날로그 및 디지털 신호 필터링 기법으로, 통과 대역(pass-band)에서 증폭이나 감쇠가 없는 평탄한 주파수 응답을 제공한다. 차수 설정을 통해 신호의 왜곡을 조절할 수 있다. 낮은 차수는 필터링의 경사가 완만해 신호의 과도 왜곡을 줄일 수 있으며, 높은 차수는 이상적인 필터 형태가 되어 신호의 왜곡을 줄일 수 있지만, 필터의 복잡도가 같이 높아지는 문제점이 존재한다(Fig 9). 본 연구에서는 차수를 4로 설정하였다. 이를 통해, 뇌파 데이터 내에 있는 노이즈(데이터 내 눈 움직임, 머리 움직임 등)를 제거하고 신호 왜곡을 최소화하였다.




Fig 7. EEG Data Signal





Fig 8. EEG Data Signal after Butterworth, band-pass Filtering



$$H(s) = \pm 1/D(s)$$

$$1^{\text{st}} : H(s) = \frac{1}{s+1}$$

$$2^{\text{nd}} : H(s) = \frac{1}{s^2 + \sqrt{2}s + 1}$$

$$3^{\text{rd}} : H(s) = \frac{1}{s^3 + 2s^2 + 2s + 1} = \frac{1}{(s+1)(s^2 + s + 1)}$$

Fig 9. Butterworth Filtering [29, 30]

이후 필터링 수행한 데이터 중 EEG Data에 대해 Band-pass Filtering을 적용하였다. Band-pass Filtering은 신호에 대해서 특정 주파수 대역만을 통과하고 다른 주파수 대역은 차단하는 방법이다 [22]. 즉, 입력으로 들어온 신호에서 설정한 주파수 범위는 그대로 필터를 통과하고, 설정한 주파수를 제외한 나머지 주파수는 필터에서 차단된다 (Fig 10). 본 연구에서는 Band-pass Filtering을 사용하였으며, 주파수 범위를 8-30Hz로 설정하였다 [8, 19, 20]. 이를 통해서, EEG 신호에서 운동 상상(Motor Imagery)과 관련된 특정 주파수 대역을 강조하고, 이를 제외한 관련 없는 대역을 제거하였다.

주파수 대역을 8-30Hz로 설정한 이유는 운동 상상과 관련된 활동과 하여 뇌파 종류 중 하나인 Alpha 파(8-12Hz), Beta 파(12-30Hz)를 강조하기 위함이다. Fig. 8에서 Fig. 7의 뇌파 데이터를 2가지의 필터링(Butterworth Filtering, Band-pass Filtering)을 수행한 결과를 확인할 수 있다.




Fig 10. Band-pass Filtering [22]

이후 필터링을 수행한 신호를 사용하여 Bad Trial을 식별하는 작업을 수행하였다. 이를 위해 시간 범위를 0.5~2.5초(s)로 설정하였다 [20]. 설정된 시간 범위에서 신호의 진폭(Amplitude)을 계산하였으며, Alpha, Beta 파와 관련된 데이터를 식별하기 위해 진폭 기준을 $\pm 100 \mu V$ 로 설정하였다 [5-7]. 진폭 값이 $\pm 100 \mu V$ 를 초과할 경우에는 Bad Trial로 분류하였다. 이를 통해 노이즈가 심하거나, 측정이 잘못된 데이터를 제거하여 추후 모델 성능 향상을 기대할 수 있다.

본 연구에서는 총 3,440개의 Trial data를 사용하였으며, 각 피험자별 Trial data로 Bad Trial 식별 작업을 수행했다. 이에 방법을 수행한 결과, 각 피험자의 Trial data에서 Bad Trial은 검출이 되지 않았으며, 모든 데이터가 정상적으로 측정되었음을 확인하였다.

Bad Trial를 식별하는 작업 중에서 또 다른 단계는 EMG Data를 사용하여 상관관계를 조사하는 과정이다 [21]. 이 단계의 주요 목적은 이전 단계에서 구현했던 각 피험자별 Trial Data 중 bad trial을 추출하는 것과 동일하며, 본 연구에서는 EMG Data를 사용하여 추출을 수행하였다.

각 피험자의 Trial 내 EMG 데이터에 Butterworth Filtering을 적용한 후에는 High-Pass Filtering를 사용하였다. High-Pass Filtering은 특정 주파수 이상의 신호만 통과시키고, 그보다 낮은 주파수 성분을 제거하는 필터링 기법이다 [23]. 이 필터는 EEG/EMG 신호 분석에서 고주파 성분을 강조하거나 저주파 노이즈(예: DC 드리프트)를 제거하기 위해 사용된다(Fig. 11).

본 연구에서는 주파수를 0.5Hz로 설정하여 EMG Data 내에 존재하는 0.5Hz 이하의 저주파의 노이즈(Drift)를 제거하고, 신호의 왜곡을 최소화하였다. 이를 통해 EMG 데이터의 품질을 개선하고 분석에 적합한 신호를 확보할 수 있었다.




Fig 11. High-Pass Filtering [23]




Fig 12. EMG Data Signal




Fig 13. EMG Data Signal after Butterworth, High-Pass Filtering

Fig 12, 13을 통해서 필터링 이전의 EMG Data의 일부 신호 형태와 제시한 2가지 필터링을 수행한 결과 신호를 동시에 확인할 수 있었다.

2가지 필터링을 수행한 EMG Data에 Common Average Reference(CAR)를 적용하였다. Common Average Reference(CAR)은 신호 내 노이즈를 제거하는 방법 중 하나로, EEG/EMG 데이터의 기준(reference) 전극을 설정한 후, 모든 채널 신호의 평균값을 기준으로 설정하여 신호를 재참조(re-referencing)하는 기법이다. 이 방법은 각 채널의 신호에서 전체 채널의 평균 신호를 빼서 공통 노이즈를 제거하고, 신호 간의 상관성을 강조한다. [24, 25].

본 연구에서는 EMG 데이터에 CAR를 적용하였다. EMG 데이터는 측정 과정에서 전극 주변 환경 등과 같이 노이즈의 영향을 받기 쉽다. CAR를 통해 모든 채널에 공통으로 존재하는 노이즈를 제거함으로써, 각 채널 신호의 상대적 차이를 강조하고 데이터 간 불필요한 변동성을 줄였다. 이를 통해 각 채널의 유효 신호를 더욱 명확히 강조할 수 있었다.

$$V_i^{CAR} = V_i - \frac{1}{N} \sum_{j=1}^N V_j$$

$V_i = i$ - 번째 채널의 원래 신호

$$\frac{1}{N} \sum_{j=1}^N V_j = \text{모든 채널 신호의 평균 값 (공통 평균)}$$

$V_i^{CAR} = CAR$ 이 적용된 i - 번째 채널 신호

다음 단계로 Band-pass Filtering을 수행하였다. 이 과정은 이전 단계에서 EEG Data에 적용했던 방법과 동일하며, 본 연구에서는 50-250Hz로 적용하였다.

뇌파 데이터마다 주파수를 다르게 설정한 이유는 EMG Data는 EEG와 달리, 근육 활동에서 움직이는 전기 신호이므로, 50-250Hz를 설정하여 근육 활동과 관련된 신호를 강조하였다. 또한, 50Hz 이하와 250Hz 이상의 노이즈(눈 움직임, 장비 간섭 등)를 제거하여 각 EMG Data의 유효한 신호를 추출하였다. 본 연구에서 적용한 결과는 다음과 같다 (Fig 14).

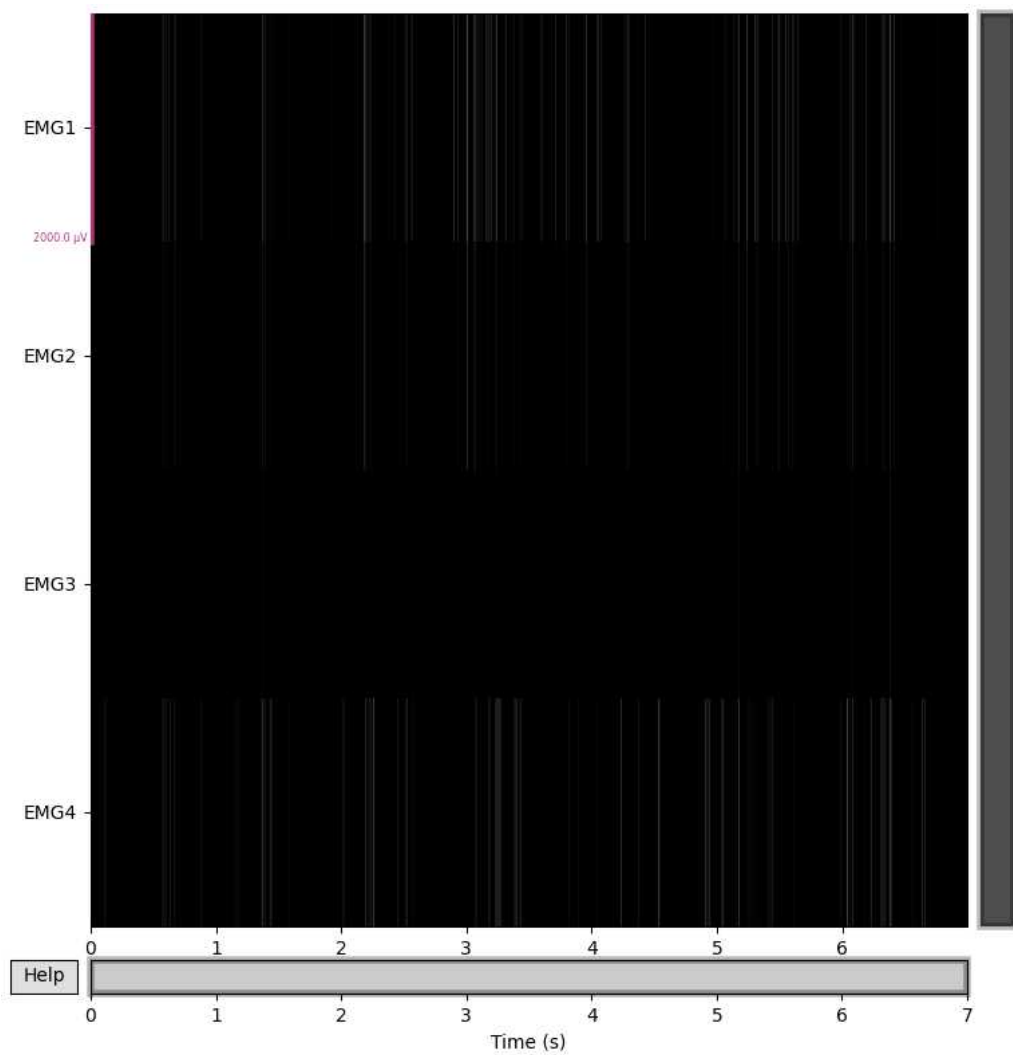


Fig 14. Common Average Reference(CAR), Band-Pass Filtering Results of EMG Signal

그 다음 단계로 Hilbert transform을 사용하였다. Hilbert Transform은 시간 기반의 신호 데이터에 대해 복소수 표현(complex representation)을 생성하는 방법으로, 신호의 진폭(amplitude)과 위상(phase) 정보를 추출할 수 있는 기법이다.

입력 신호로부터 복소수 신호를 생성 :

$$x_H(t) = x(t) + j^* Hx(t)$$

$x(t)$: 원래 신호 (실수 신호)

$Hx(t)$: Hilbert Transform으로 얻은 허수부 (Imaginary Part)

$x_H(t)$: Hilbert 변환 결과 (복소수 신호)

여기서, 진폭과 위상은 각각의 방법을 통해 추출할 수 있었다.

$$A(t) = |x_H(t)| = \sqrt{x(t)^2 + Hx(t)^2}$$

$$\Phi(t) = \tan^{-1}\left(\frac{Hx(t)}{x(t)}\right)$$

본 연구에서는 필터링을 거친 EMG Data에서 진폭 및 위상 정보를 추출하였다. 이 과정에서는 신호의 진폭 추출을 중점으로 수행하였다.

| | | |
|--------------------|--------------------|--------------------|
| 3966.849238922613 | 37127.811579037516 | 24844.939660144315 |
| 4292.562312450982 | 8060.3554668195875 | 9565.585768247929 |
| 3827.4439435996887 | 18758.356213090785 | 11285.69400805483 |
| 7567.82571288274 | 11433.68467383039 | 7072.9888505549025 |

Fig 15. Hilbert Transform Magnitudes of EMG Signals

그다음으로 Rest 구간, Task 기반 구간을 설정하였다. 본 연구에서는 각 -1, +1를 라벨(Label)로 설정하였다. 또한, 각 구간을 각각 신호의 -1000-0ms, 0-3000ms를 구간으로 설정하였다. 각 구간은 휴식 구간(Resting Window), Task 기반 구간(Task-related Window)으로 정의하였다.

이후 Pearson Correlation을 수행하였다. Pearson Correlation은 두 변수 간의 선형 관계를 측정하는 통계적 기법으로, 결과 값은 -1~1의 사이로 나타난다. 이를 통해서 두 변수 간의 선형 관계를 알 수 있습니다.

$r > 0$: 양의 선형 관계.

$r < 0$: 음의 선형 관계.

$r = 0$: 선형 관계 없음.

본 연구에서는 EMG Data의 각 Channel 신호와 설정한 라벨을 대상으로 하였다. 이후 상관관계로 검증된 라벨과 EMG data 간에 추가적인 Pearson Correlation을 수행하였다. Correlation 적용된 결과인 r 값이 높을 수록 신호와 라벨이 연관성이 높음을 의미한다.

이후 Bonferroni-corrected P-value를 수행하여 Pearson 결과에서 나온 correlation 값에서 다중 검정으로 인한 오류 가능성을 줄이는 과정을 수행하였다. Bonferroni-corrected P-value는 다중 비교(multiple comparisons) 문제를 해결하기 위한 통계적 방법으로, 여러 번의 검정을 수행할 때 우연히 유의미한 결과가 나올 확률을 줄여준다. 이를 통해 false positive(거짓 양성) 결과를 줄일 수 있다.

$$P_{corrected} = P_{raw} * m$$

$$P_{raw} = \text{Pearson Correlation}$$

$$m = \text{검정의 수 (Permutations)}$$

본 연구에서는 Bonferroni-corrected P-value와 Pearson correlation을 사용하여 bad trial 여부를 결정하였다. 본 연구에서 임계값은 각각 0.01, 0.8로 설정하였다 [1].

Bad Trial 여부를 검사한 후, Trial data 중 Bad Trial을 제거하여 이후 단계에서 모델에 적용할 데이터를 수집하였다.

다음 단계에서는 특징 추출을 수행하였다. 특징 추출은 뇌파 데이터에서 고유한 특징을 추출하여 추후 단계의 모델에 적용함으로써 분류 성능을 향상시키는 과정을 의미한다.

본 연구에서 사용한 특징 추출 기법으로 CSP, Wavelet Transform을 사용하였다. CSP는 Common Spatial Patterns을 말하는 것으로, 두 개의 클래스가 존재한다면, 클래스 간의 분산(variance)의 비율 차이를 극대화하는 공간 필터를 학습하는 방법으로, 필터링 후 신호의 분산을 분석하여 특징 벡터를 생성한다. [19, 20] 본 연구에서는 좌/우(Left/Right)를 클래스 기준으로 설정하였으며, 또한 공간(Spatial)을 2차원으로 지정하여 좌/우의 분산 비율 차이를 극대화하는 필터를 학습하였다.

또한 CSP 방법 외에도 Wavelet Transform을 사용하였다. Wavelet Transform은 신호를 시간과 주파수의 동시 도메인에서 분석할 수 있도록 설계된 변환 기법이다. 이 방법은 신호의 특정 시간 구간에서 주파수 정보를 분석할 수 있으며, 다중 해상도 분석(Multi-Resolution Analysis)을 통해 신호의 낮은 주파수에서는 긴 시간 간격, 높은 주파수에서는 짧은 시간 간격으로 분석이 가능하다. EEG/EMG와 같이 뇌파 데이터는 시간에 따라 변화하는 특성을 가지므로, Wavelet Transform을 통해 신호를 효과적으로 분석할 수 있다.

Wavelet Transform은 다음 과정을 통해 수행된다.

$$W(a, b) = \int_{-\infty}^{\infty} x(t) * \Psi^* \left(\frac{t-b}{a} \right) dt$$

여기서 사용된 파라미터는 다음과 같다.

$x(t)$: 입력 신호, $\psi(t)$: 모함수(wavelet function), a : 스케일(scale) 파라미터, 신호의 주파수 구성요소를 조정, b : 시간(time) 파라미터, 시간적 위치를 조정, $*$: 복소수 공액 복소수

본 방정식을 사용하여 각 뇌파 데이터에서 신호의 특징을 추출하였다.

II-3 분류 모델

2.3.1 FLDA

본 연구에서 사용된 분류 모델은 Fisher's Linear Discriminant Analysis (FLDA)이다. FLDA는 머신러닝과 통계학에서 사용되는 고전적인 차원 축소 및 분류 기법으로, 두 개의 클래스를 효과적으로 분류하기 위해 설계되었다. FLDA는 각 클래스의 분산을 최소화하면서 두 클래스 간의 분리 정도를 최대화하여, 클래스 간의 분산 비율(클래스 간 분산 / 클래스 내 분산)을 최대화하는 선형 결정 경계를 찾는다. 즉, 선형 변환을 통해 데이터를 낮은 차원(1차원 또는 2차원)으로 투영하여 분류한다.

FLDA는 다음 과정에서 수행한다. S_B 는 클래스 간 분산, S_W 는 클래스 내 분산으로 각각 계산하며, S_B 는 클래스 간 평균 차이를 의미한다. S_B 를 계산하는 방법은 다음과 같다.

$$S_B = (\mu_1, \mu_2) * (\mu_1, \mu_2)^T$$

이때, 여기서 μ_1, μ_2 는 두 클래스의 평균 벡터를 의미한다.

다음은 클래스 내 분산(S_W)을 계산한다. S_W 는 각 클래스 내에 있는 데이터 분산을 의미하며, 계산하는 방법은 다음과 같다.

$$S_W = \sum_{i \in class 1} (x_i - \mu_1)(x_i - \mu_1)^T + \sum_{i \in class 2} (x_i - \mu_2)(x_i - \mu_2)^T$$

FLDA는 클래스 간 분산(S_B)과 클래스 내 분산(S_W)의 비율(S_B/S_W)을 최대화하는 방향, 즉 최적의 벡터를 찾는다.

$$w = S_W^{-1}(\mu_1 - \mu_2)$$

이를 바탕으로 데이터를 해당 벡터(w) 방향으로 투영하여 낮은 차원으로 변환한다. 이때, 분류는 다음 식에 따라 수행된다.

$$y = w^T x$$

본 연구에서는 FLDA를 사용하여 Left/Right 라벨을 기준으로 데이터를 분류하였다. 즉, Left/Right를 기준으로 데이터를 투영하여 분류하는 방식을 적용하였다. FLDA에 사용된 입력 데이터는 첫 번째 단계에서 bad trial을 제거한 EEG data이다. 이 데이터는 CSP(Common Spatial Reference)를 사용하여 특징을 추출하였으며, 2차원 공간(Spatial)를 지정하여 각 EEG data의 고유 특징을 추출하였다(Fig 9).

2.3.2 SVM

본 연구에서는 사용된 모델 중 하나로 Support Vector Machine(SVM)을 활용하였다. SVM은 두 클래스를 최대한 분리할 수 있는 초평면(hyperplane)을 찾는 분류 알고리즘으로, 선형 데이터와 비선형 데이터를 모두 처리할 수 있다. 특히, SVM은 Linear, Poly와 같은 커널 함수를 사용하여 비선형 데이터도 효과적으로 분리할 수 있는 것이 특징이다.

SVM의 핵심은 두 클래스 간의 데이터를 구분하는 초평면을 찾는 것이다. 이 과정에서 각 클래스가 초평면으로부터 최대한 멀리 떨어지도록 수행된다. 해당 과정은 초평면은 방향 벡터 w 와 절편 b 로 정의되며, 이를 바탕으로 데이터를 분리한다.

$$w^T x + b = 0$$

다음으로, SVM은 최대 마진(margin)을 정의한다. 마진은 초평면에서 가장 가까운 데이터 포인트(Support Vectors)까지의 거리로, SVM은 이 마진을 최대화하는 w 와 b 를 찾는 과정을 수행한다. 이를 통해 두 클래스 간의 분리도를 극대화한다.

$$\max \frac{2}{\|w\|}$$
$$y_i(w^T x_i + b) \geq 1 \quad \forall i$$

또한, SVM은 커널 함수를 사용하여 데이터를 더 높은 차원의 공간으로 변환한다. 이때, 커널 함수는 Linear, Poly가 대표적이다.

본 연구에서는 Linear 커널 함수를 사용하여 데이터를 선형적으로 변환하고, 각 클래스를 Left/Right로 설정하여 SVM 모델에 적용하였다.

2.3.3 SGD

본 연구에서 사용된 분류 모델 중 하나는 Stochastic Gradient Descent(SGD)이다. SGD는 데이터셋의 일부인 미니 배치를 사용하여 경사하강법(Gradient Descent)을 빠르게 계산하는 최적화 알고리즘이다. 모델의 가중치(Weight)를 경사하강법을 통해 업데이트하며, 손실 함수를 최소화하는 것을 목표로 한다.

$$w = w - \eta * \nabla J_i(w)$$

해당 과정에서 w 는 모델의 가중치 벡터, η 는 학습률(Learning Rate), $J(w)$ 는 데이터 샘플 I 에 대한 손실함수를 의미한다.

이를 통해 미니 배치를 사용해 손실함수를 계산하고, 모델의 가중치를 업데이트한다.

SGD는 EEG와 같은 실시간 데이터, 또는 대량의 데이터를 학습하는 것에 적합한 장점을 가진다. 따라서, 본 연구에서는 EEG 데이터를 활용하여 효과적으로 학습을 수행하였다.

본 연구에서는 하이퍼파라미터를 다음과 같이 설정하였다.

첫 번째로, `max_iter`를 1000으로 설정하여 가중치 업데이트 반복 횟수를 1000번까지 허용하였다. 해당 값을 초과한다면, 학습을 중지하도록 하였다.

두 번째로, `tol` 값을 10^{-3} 로 설정하여 경사 값이 10^{-3} 이하로 작아질 경우, 학습을 중지하도록 하였다.

2.3.4 MLP

본 연구에서 사용된 분류 모델 중 하나는 Multi-Layer Perceptron(MLP)이다. MLP는 신경망 모델의 한 형태로, 1개 이상의 은닉층(Hidden Layer)으로 구성된다. 모델 구성은 Input Layer, Hidden Layer, Output Layer로 구성되며, Input Layer에서 데이터를 입력받아 Hidden Layer를 거치면서 가중치와 bias를 통해 데이터를 변환한다.

$$z = Wx + b$$

MLP에서 데이터 변환은 z 방정식을 통해 이루어지며, 변환된 값은 활성화 함수(Activation Function)를 사용하여 계산된다.


$$a = \sigma(z)$$

계산된 결과값 a 는 다음 단계에서 오차 계산에 사용된다.

$$Loss = L(y_{true}, y_{pred})$$

이후, 모델의 출력값과 실제 레이블 간의 오차를 계산하고, 이 오차를 바탕으로 Backpropagation(역전파)을 통해 가중치를 업데이트한다.

$$W = W - \eta^* \nabla \mathcal{L}$$



본 연구에서는 하이퍼파라미터를 다음과 같이 설정하였다.

첫 번째로, max_iter를 500으로 설정하여, 최대 반복 학습 횟수를 500번으로 설정하여, 해당 값을 초과하면 학습을 중단하도록 하였다.

두 번째로, hidden_layer_sizes를 (100,)으로 설정하여, 단일 은닉층을 구성하였고, 은닉층에서는 100개의 뉴런으로 구성하였다.

세 번째로, 변화 값은 10^{-4} 로 설정하여, 손실함수 값이 변화 값보다 작다면, 학습을 중단하도록 하였다.

III. 연구 결과

제3장에서는 본 연구의 실험 결과를 소개한다. 본 실험에서는 The Biosemi ActiveTwo System, BCI2000 system 3.0.2를 사용하여 뇌파 데이터를 수집하였으며, 동시에 각 팔의 굴곡근과 신전근 부분에서도 패치를 부착하여 EMG Data를 수집하였다. 수집된 데이터 중 EEG Data를 활용하여 모델에 적용하였다. 분류 작업은 각 피험자별 데이터를 기반으로 수행하였으며, Left/Right를 클래스로 설정하여 진행하였다. 또한, 모델 적용하기 위해 특징 추출기를 사용하였으며, 본 연구에서는 Common Spatial Patterns(CSP)와 Wavelet Transform을 특징 추출기로 사용하였다.

본 장에서는 특징 추출 방법에 따른 데이터의 특성과 다양한 분류 모델을 적용한 결과를 제시한다. 사용한 분류 모델은 Fisher's Linear Discriminant Analysis (FLDA), Support Vector Machine (SVM), Stochastic Gradient Descent (SGD), Multi-Layer Perceptron (MLP)이다.

3.1 특징 추출 형태

본 연구에서는 각 데이터를 모델에 적용하기 위해 특징을 추출하였으며, 추출된 특징을 바탕으로 분류를 수행하였다. 본 연구 결과에서는 각 특징 추출 기법에 따른 데이터의 결과를 도출했다. 본 연구에서 사용한 특징 추출기는 Common Spatial Patterns(CSP), Wavelet Transform을 사용하였다.

본 장에서는 본 연구에서 사용한 두 가지 특징 추출 형태를 제시하며, 각 CSP, Wavelet Transform 순으로 형태를 확인한다.




Fig 16. Common Spatial Patterns based Data Features

CSP 기반을 사용한 데이터 특징을 다음과 같이 확인해 볼 수가 있다(Fig. 16). 본 연구에서는 Left/Right를 모델의 라벨(Label)로 설정하였으며, component를 2로 설정하여 Left, Right의 특징을 추출하였다.

이러한 형태는 각 Trial Data에서 비슷한 형태로 출력되었다. Fig. 16에서는 데이터의 모양(shape)을 확인할 수 있으며, 데이터는 (200, 2)와 같은 형태로 나타났다. 이는 데이터의 형태가 (Trial Data 개수, 2)로 구성됨을 의미한다. 여기서, Trial Data 개수는 각 피험자별 Trial Data 개수를 나타낸다. 대부분 피험자는 대부분 200개 형태로 나오나, 일부 데이터는 240개의 경우도 존재한다. 그래서, 각각 (200, 2), (240, 2)의 데이터 모양을 확인하였다 (Table. 2).

Table 2. CSP based Data Features Shape

| subject | Data Shape |
|---------|------------|
| s1 | (200, 2) |
| s3 | (200, 2) |
| s4 | (200, 2) |
| s5 | (200, 2) |
| s6 | (200, 2) |
| s9 | (240, 2) |
| s10 | (200, 2) |
| s13 | (200, 2) |
| s14 | (200, 2) |
| s33 | (200, 2) |
| s35 | (200, 2) |
| s41 | (200, 2) |
| s43 | (200, 2) |
| s44 | (200, 2) |
| s46 | (240, 2) |
| s48 | (200, 2) |
| s49 | (200, 2) |
| s50 | (200, 2) |
| s52 | (200, 2) |



Fig 17. Wavelet Transform based Data Features

Wavelet Transform 방법을 사용하여 나온 특징 추출 결과를 다음과 같이 확인할 수 있다(Fig. 17). 본 연구에서는 Left/Right를 모델의 라벨(Label)로 설정하였으며, component를 2로 설정하여 Left, Right의 특징을 추출하였다.

데이터의 모양(shape)은 다음과 같이 확인할 수 있었다(Fig. 17). 데이터의 모양은 (200, 256)와 같은 형태로 출력했으며, 이는 데이터 형태는 (Trial Data 개수, 256)의 형태로 출력했다. 여기서, Trial Data 개수는 각 피험자별 Trial Data 개수를 나타낸다. 대부분 피험자는 200개 형태이나, 일부 데이터는 240개의 경우도 존재한다. 그래서, 각각 (200, 256), (240, 256)의 데이터 모양을 확인하였다(Table. 3).

Table 3. Wavelet Transform based Data Features Shape

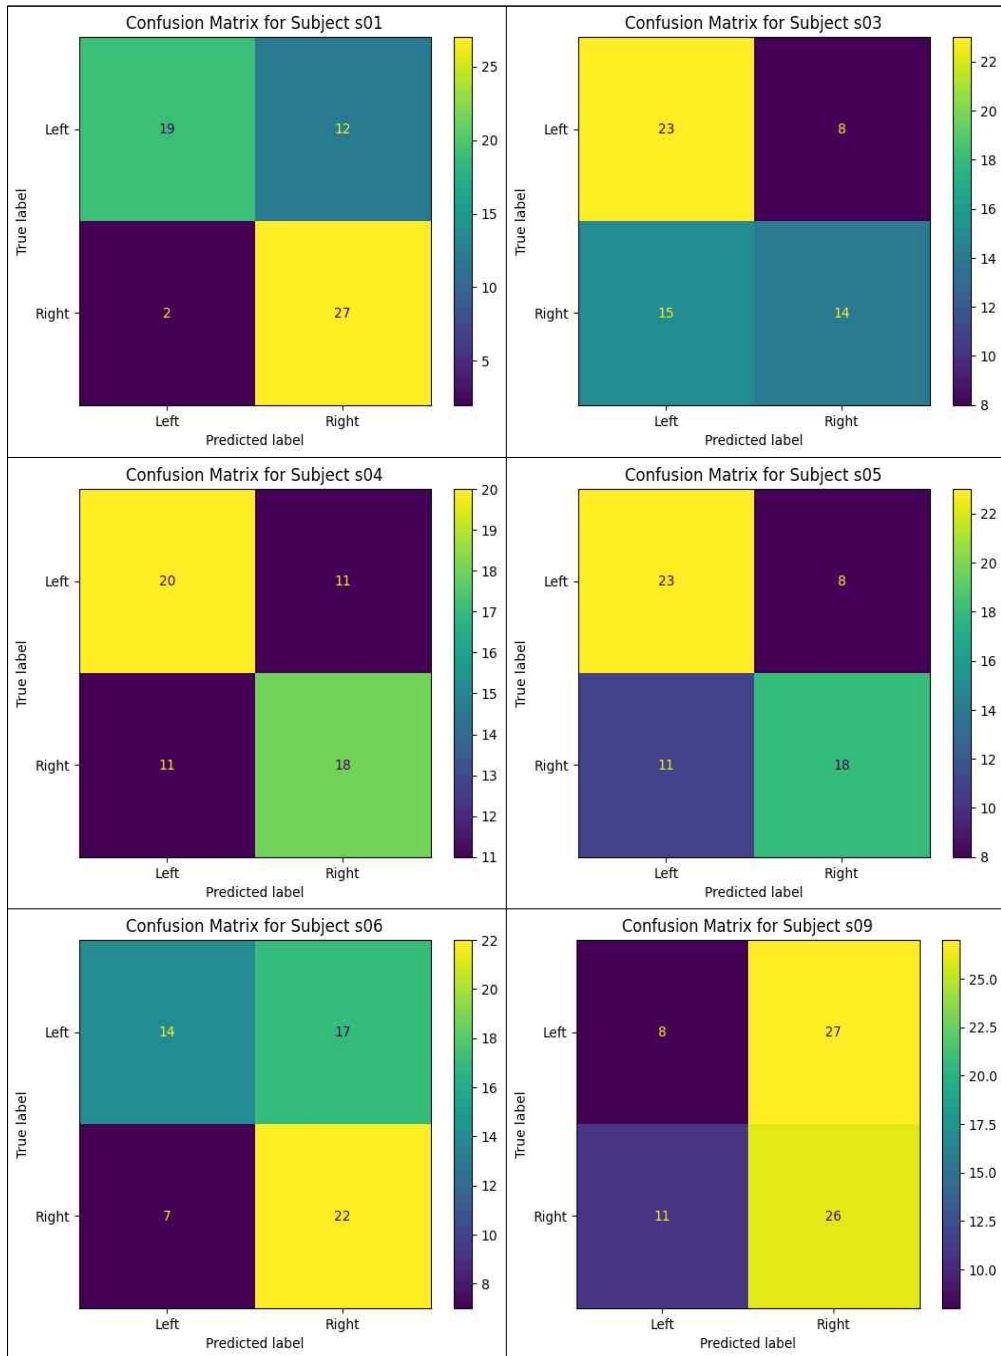
| subject | Data Shape |
|---------|------------|
| s1 | (200, 256) |
| s3 | (200, 256) |
| s4 | (200, 256) |
| s5 | (200, 256) |
| s6 | (200, 256) |
| s9 | (240, 256) |
| s10 | (200, 256) |
| s13 | (200, 256) |
| s14 | (200, 256) |
| s33 | (200, 256) |
| s35 | (200, 256) |
| s41 | (200, 256) |
| s43 | (200, 256) |
| s44 | (200, 256) |
| s46 | (240, 256) |
| s48 | (200, 256) |
| s49 | (200, 256) |
| s50 | (200, 256) |
| s52 | (200, 256) |

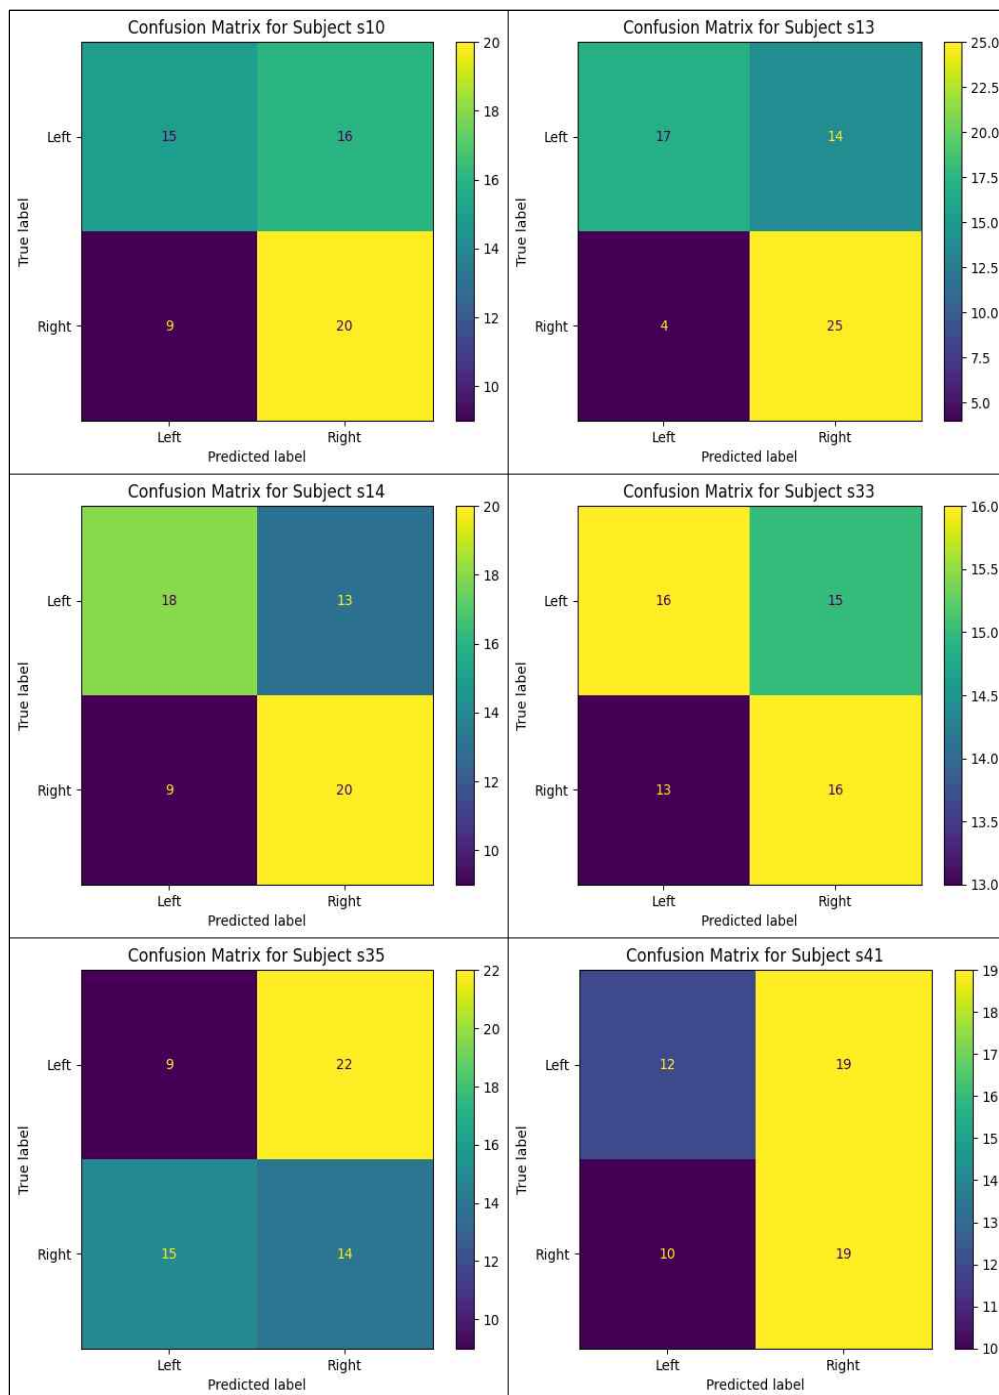
3.2 피험자별(trial data) 성능 평가

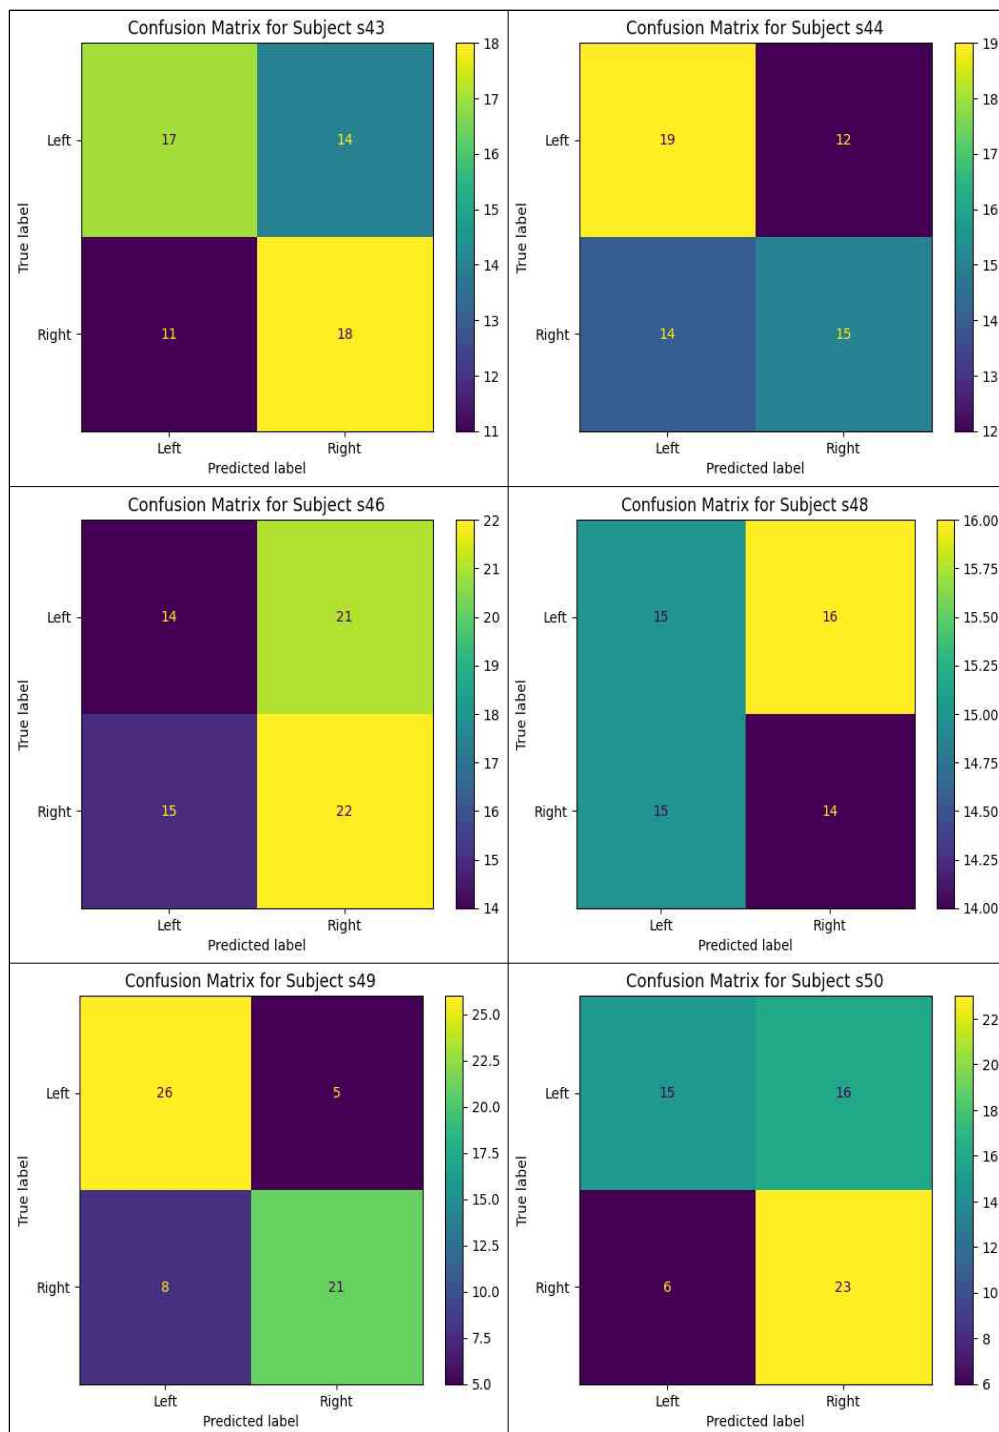
본 연구에서는 전처리 과정을 수행한 각 피험자별 데이터를 특징 추출기를 수행한 후 분류 모델에 적용하였다. 사용된 특징 추출기는 Common Spatial Pattern (CSP), Wavelet Transform이며, 분류 모델은 Fisher's Linear Discriminant Analysis (FLDA), Support Vector Machine (SVM), Stochastic Gradient Descent (SGD), Multi-Layer Perceptron (MLP)를 사용하였다. 본 결과에서는 특징 추출기별로 모델 결과를 도출했다.

본 장은 CSP를 기준으로 Confusion Matrix 결과(Fig 18-21), Wavelet Transform을 기준으로 Confusion Matrix 결과(Fig 22-25), 각 특징 추출기별 모델 성능 결과 순으로 확인할 수 있다(Table 4-5).

3.2.1 Common Spatial Pattern(CSP) 적용 결과








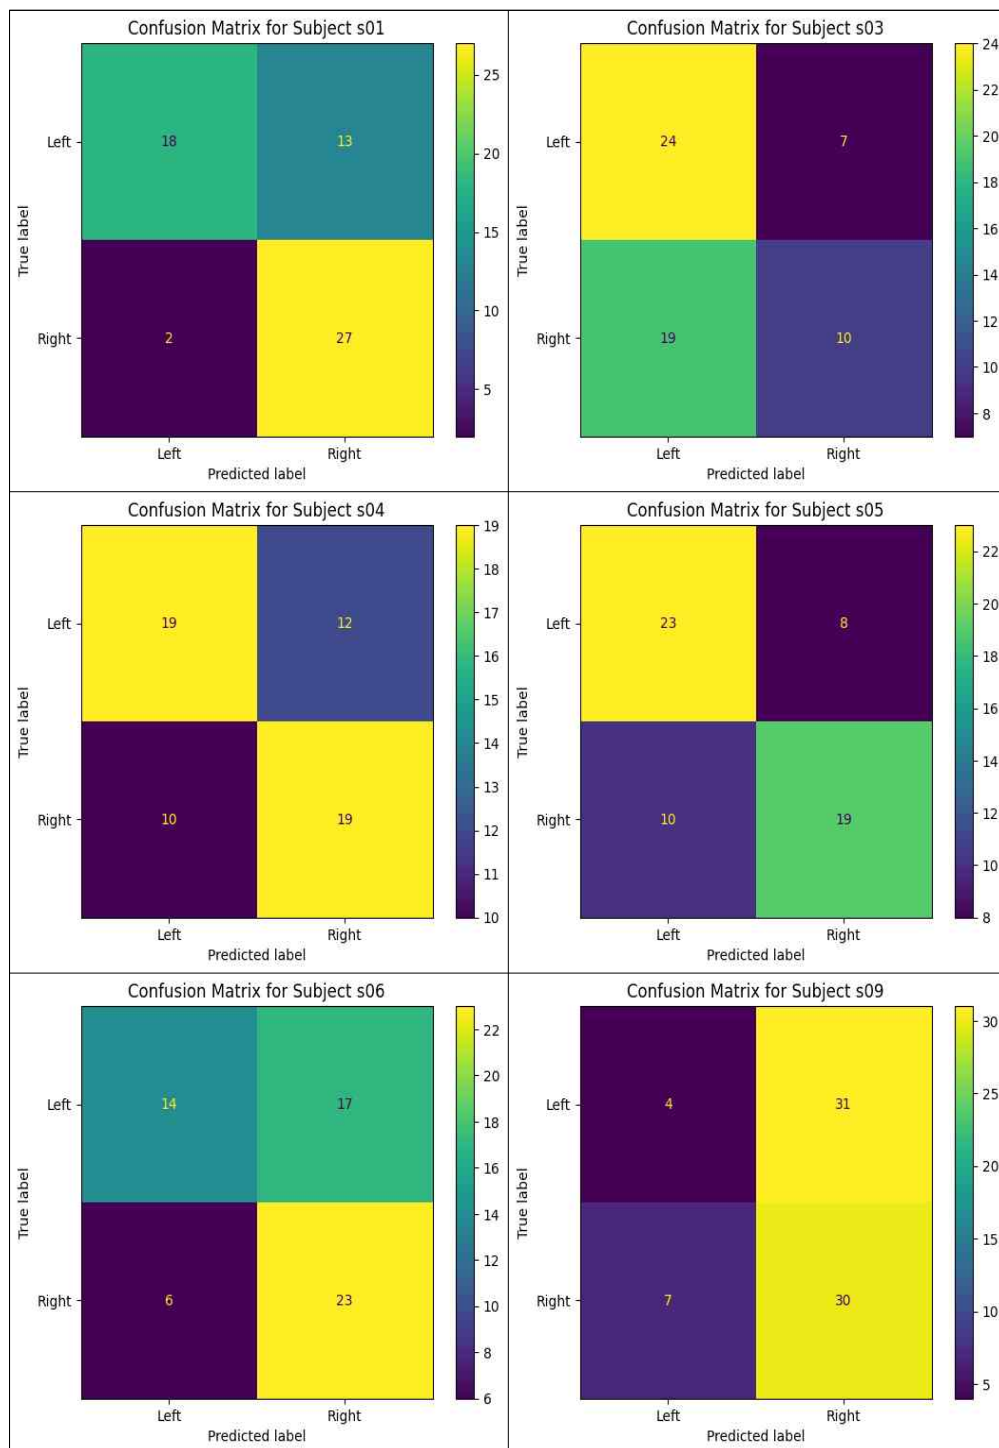
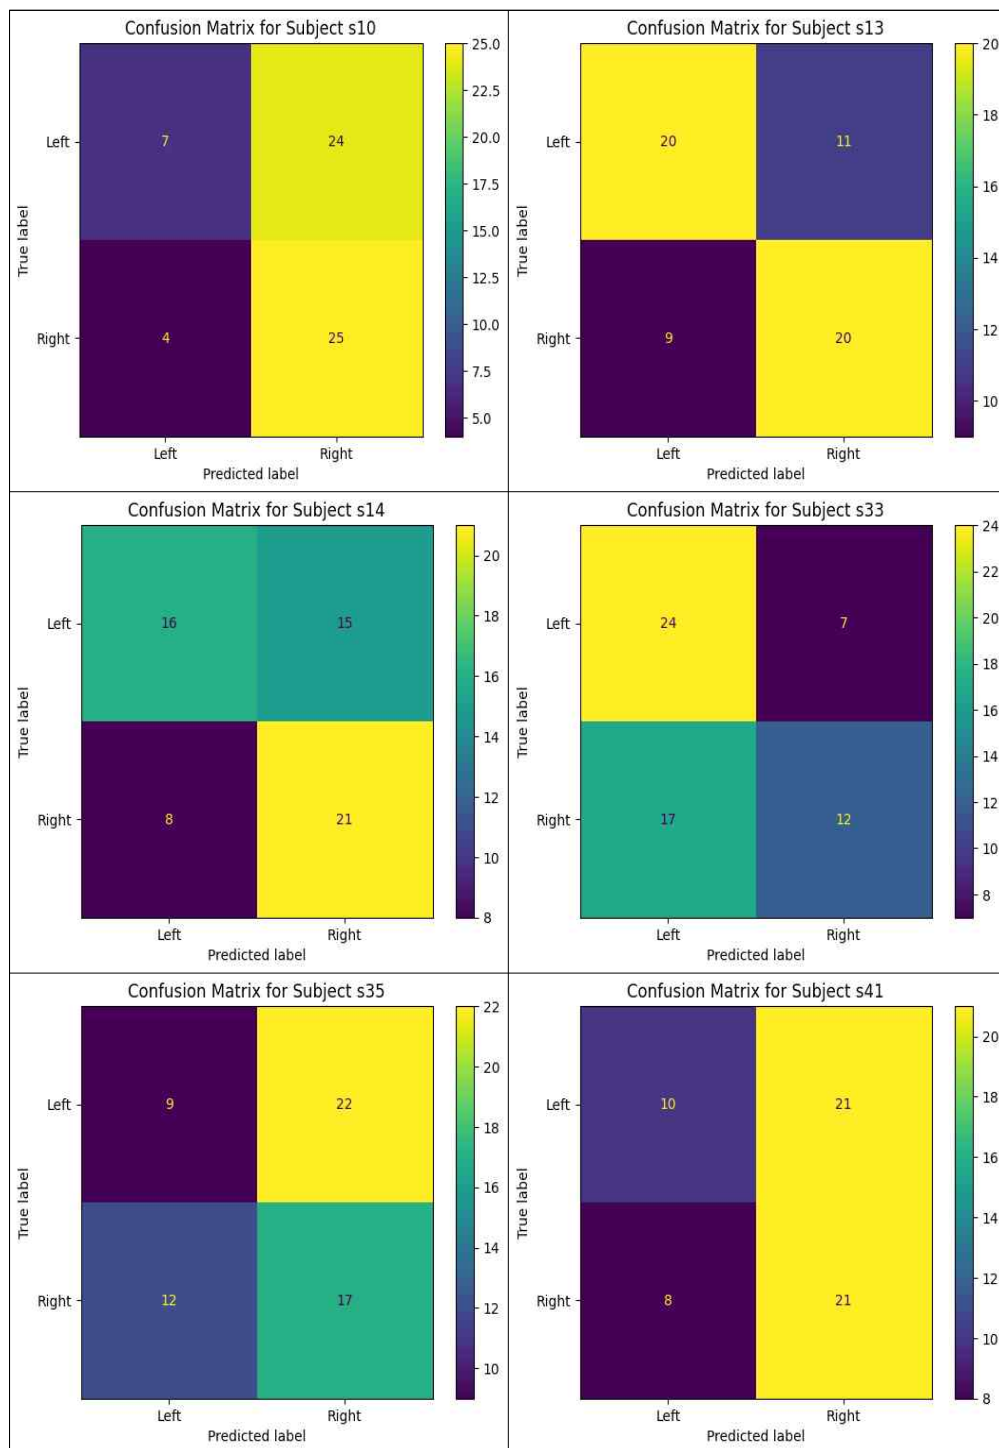
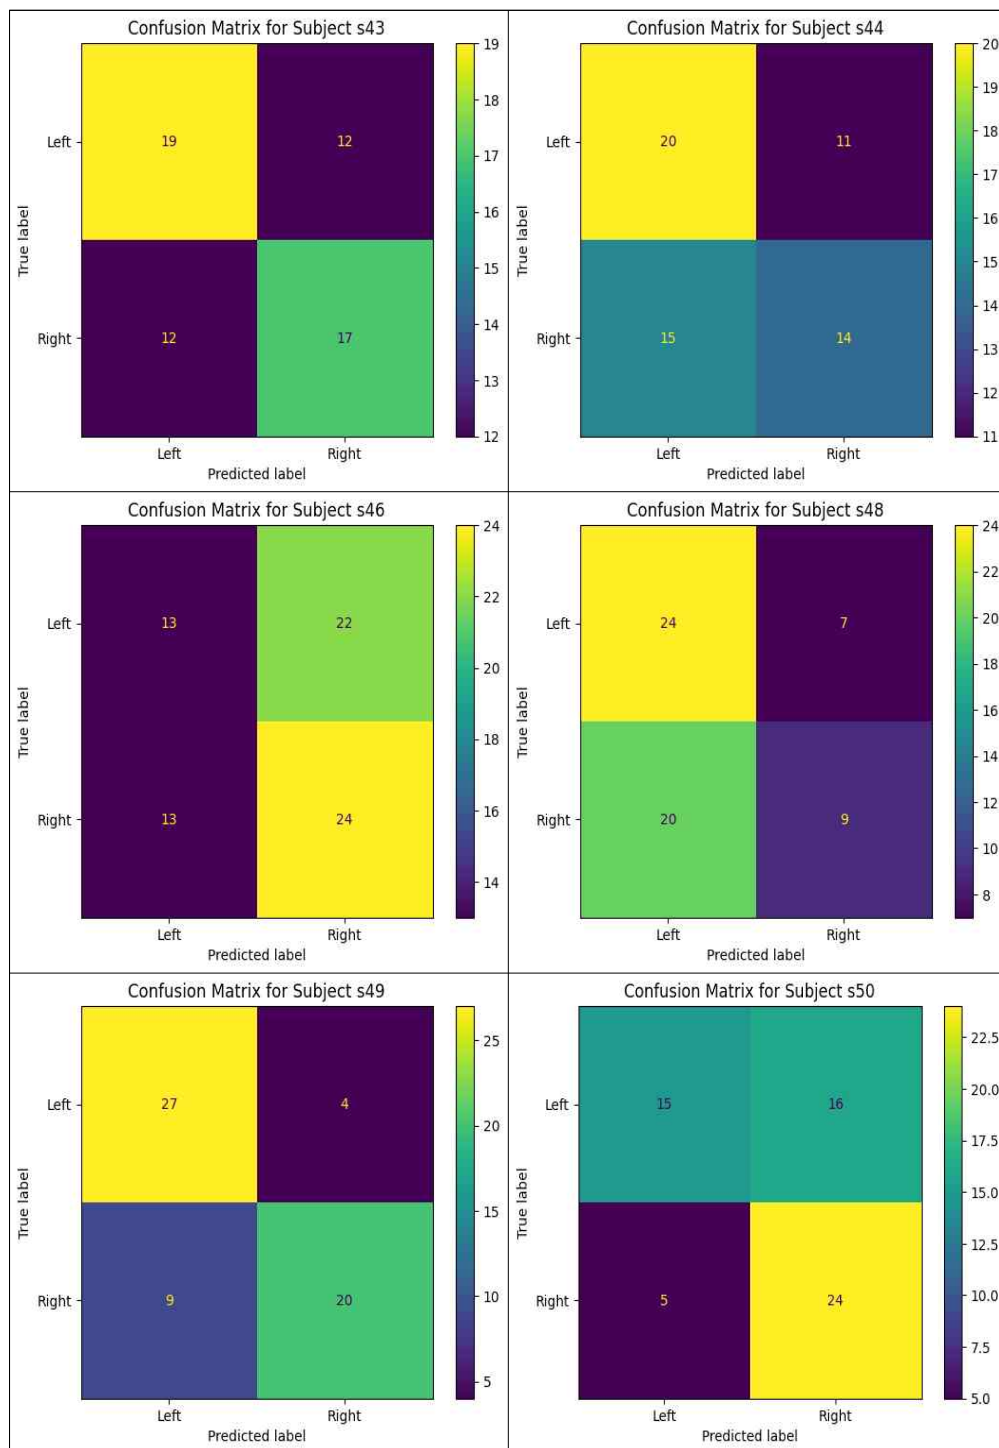


Fig 18. Confusion Matrix of individual dataset with CSP, FLDA







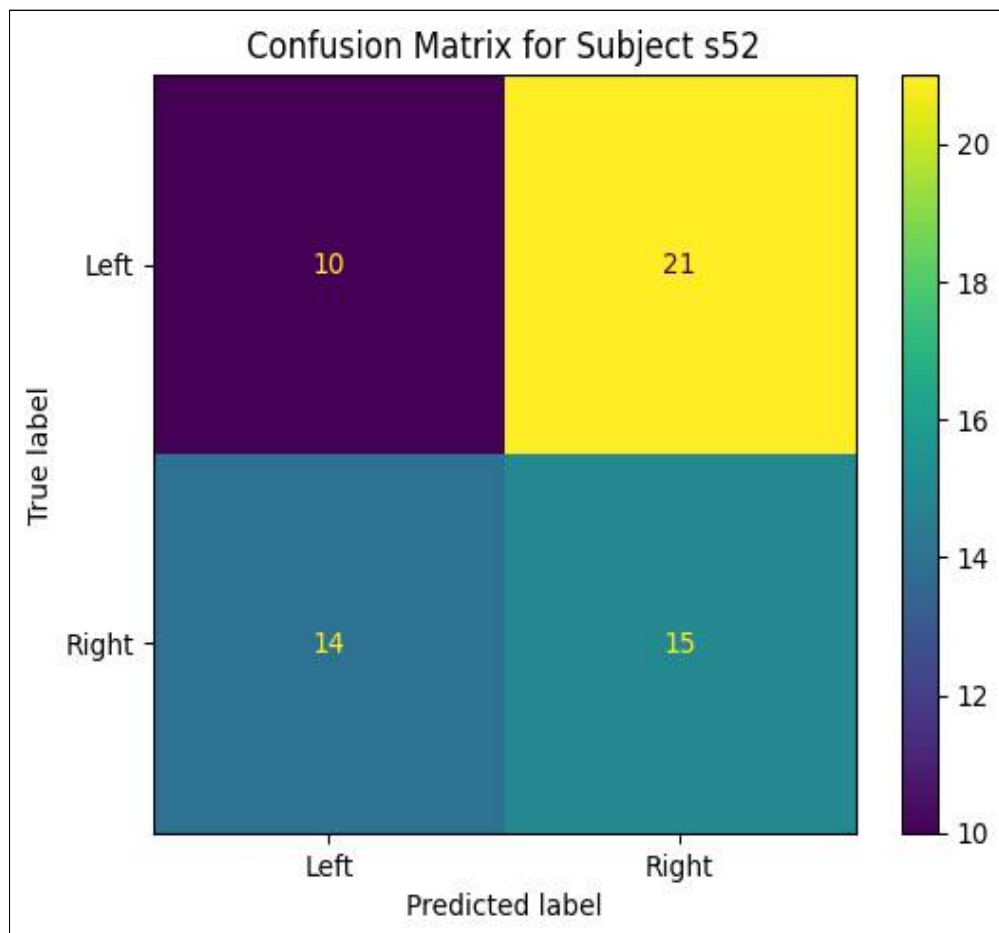
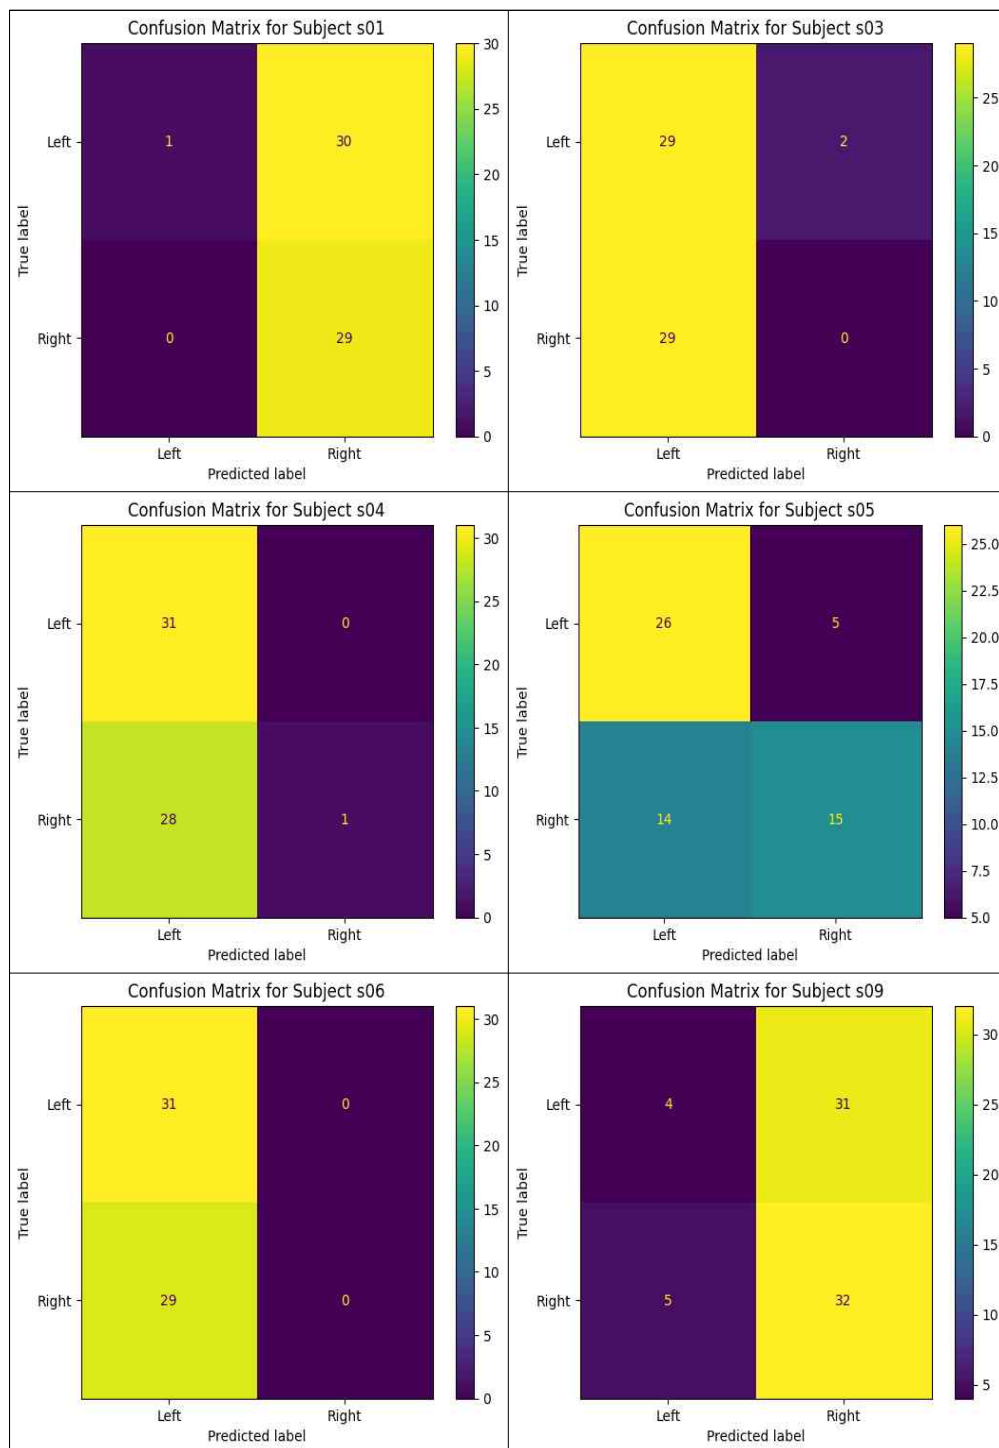
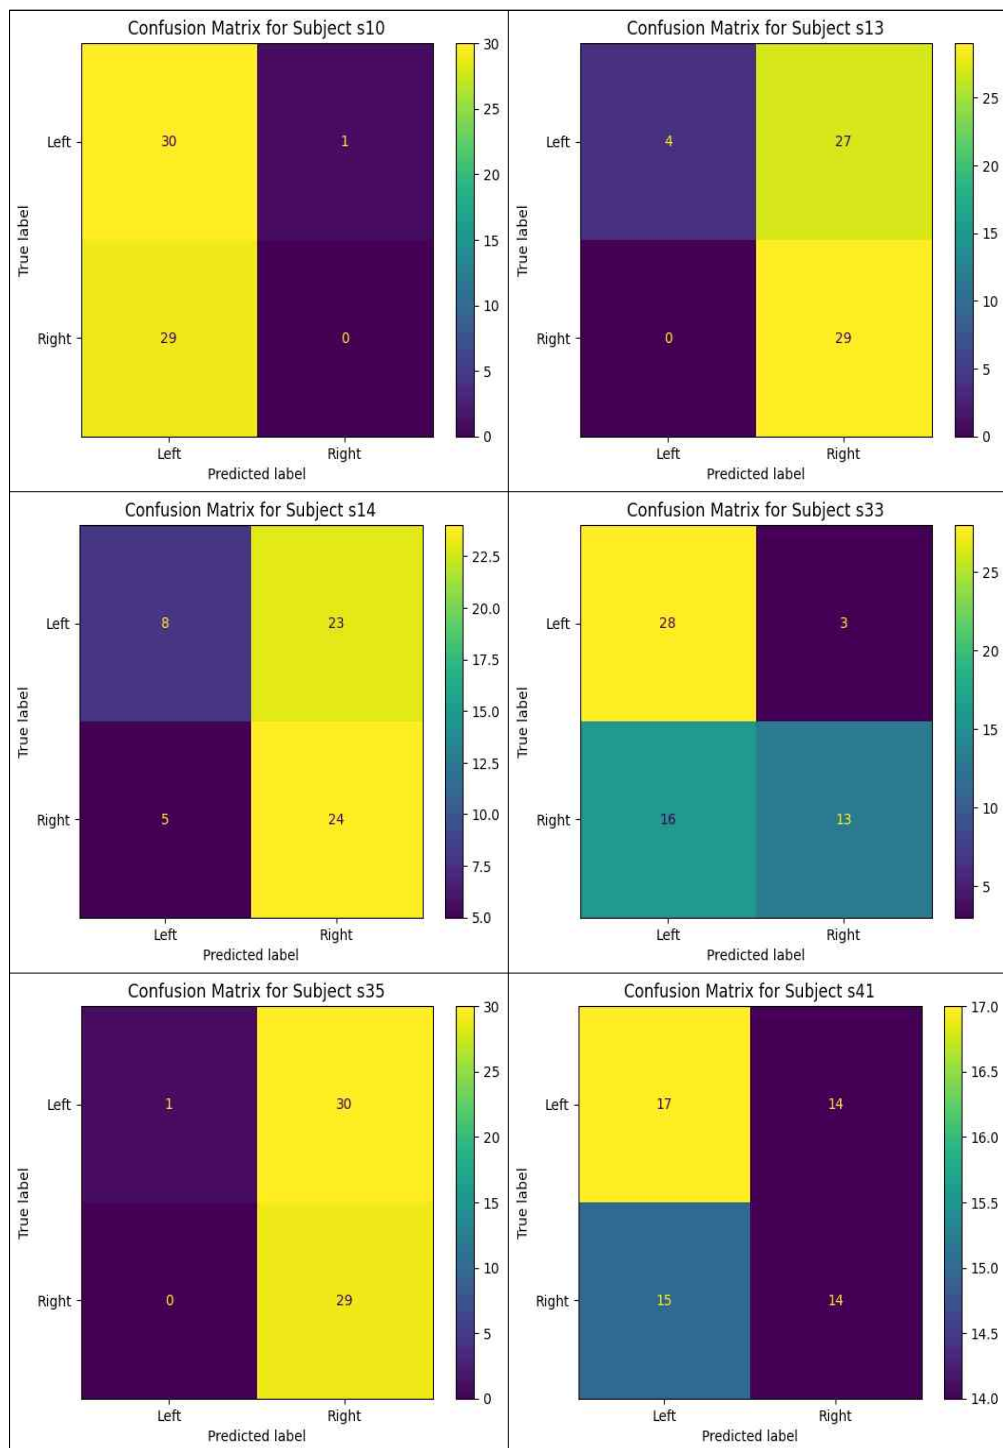
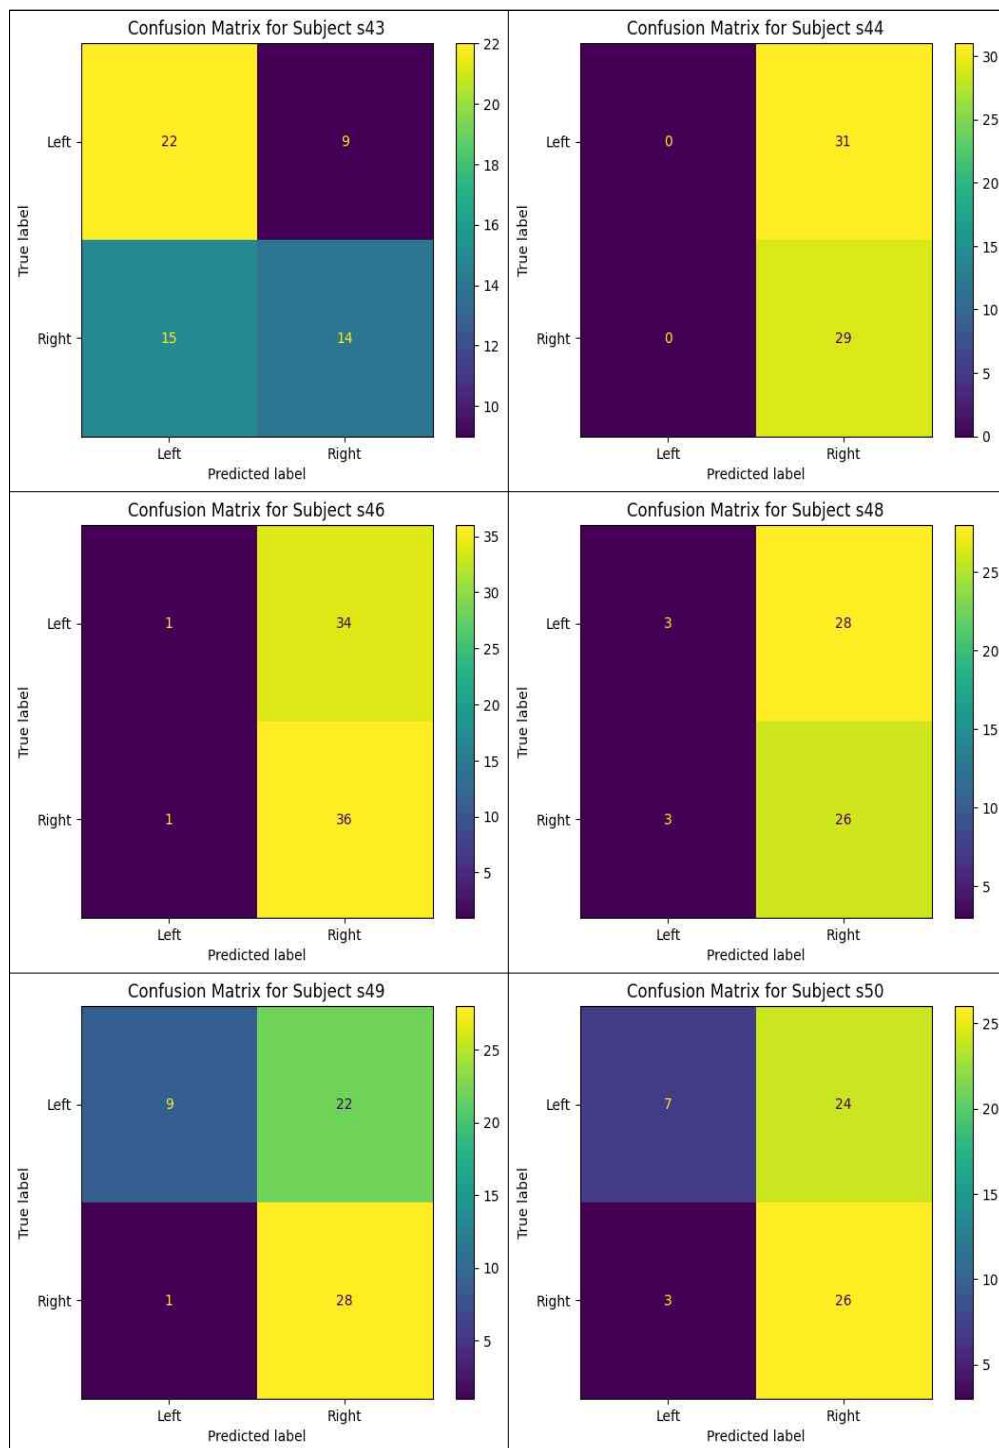


Fig 19. Confusion Matrix of individual dataset with CSP, SVM








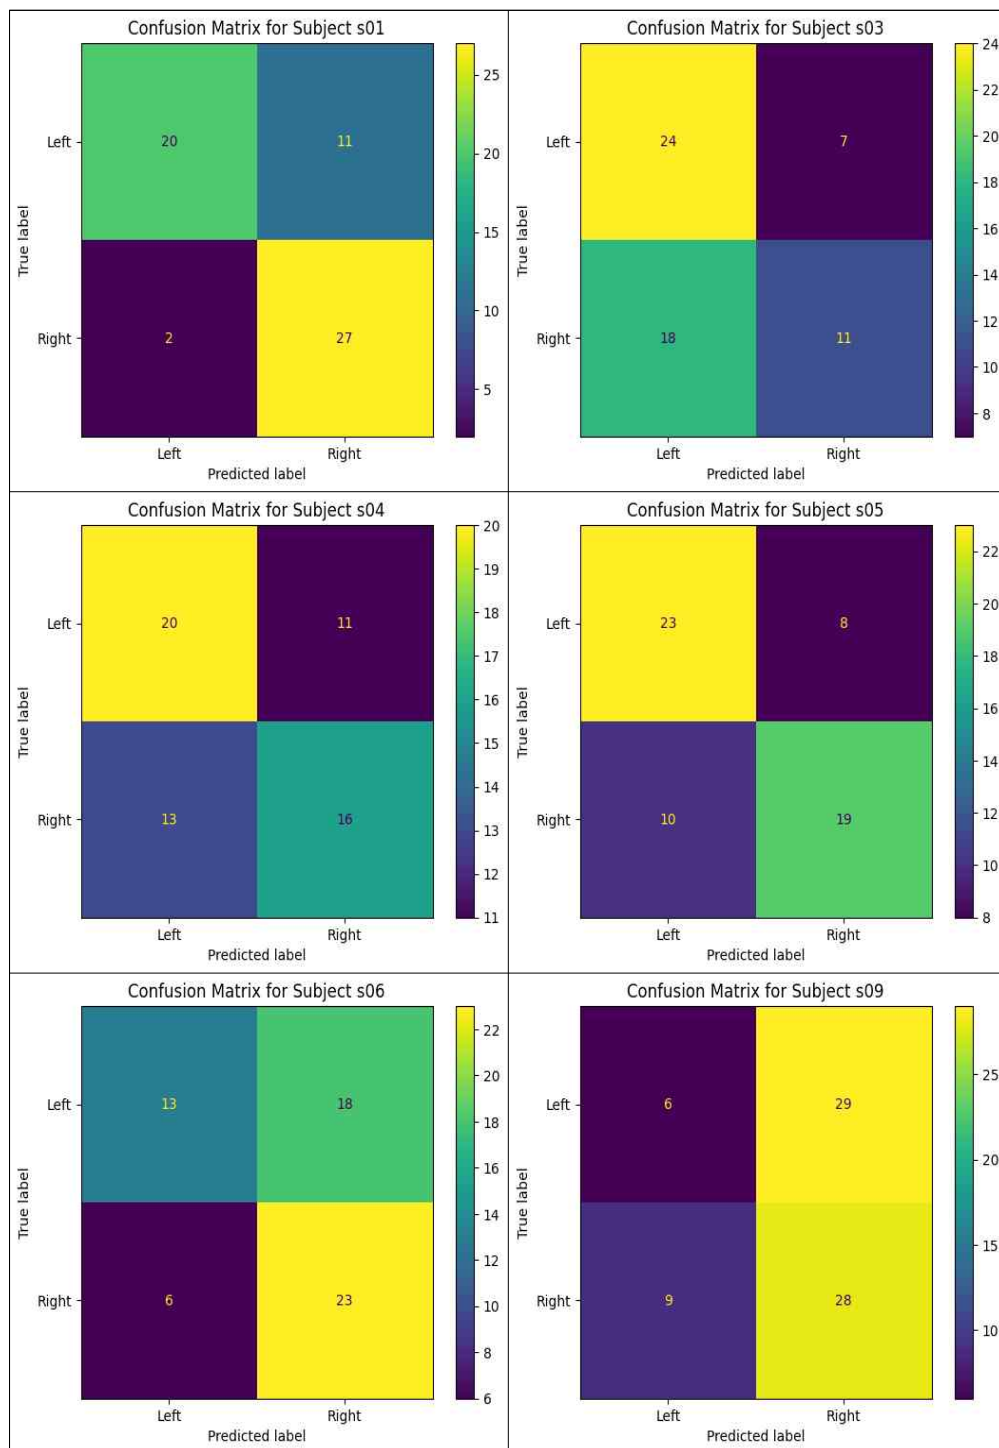
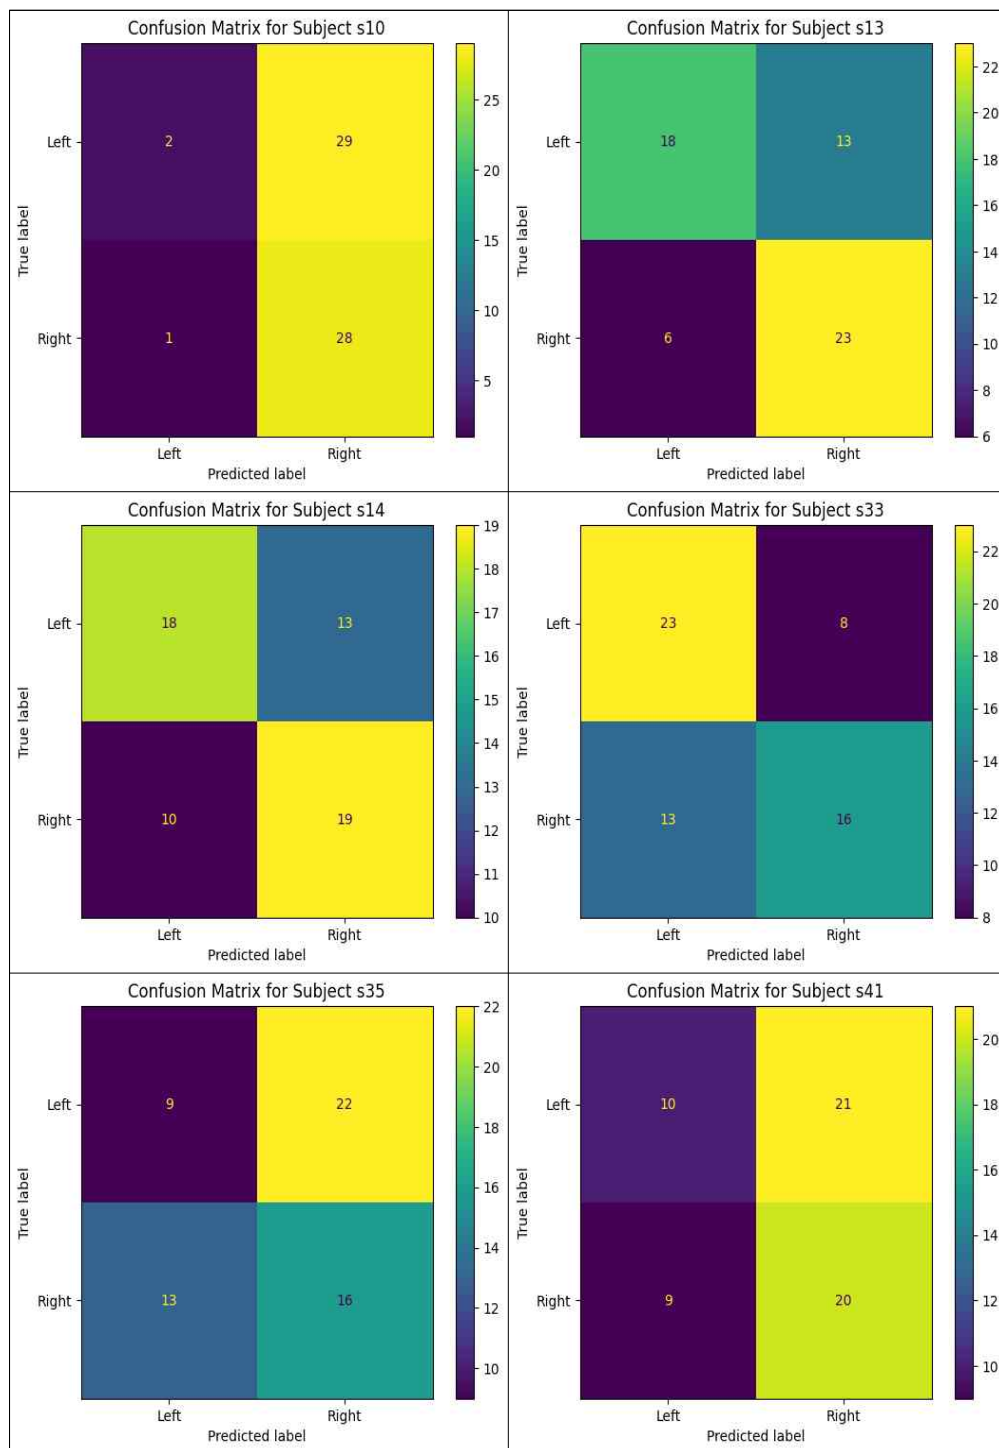
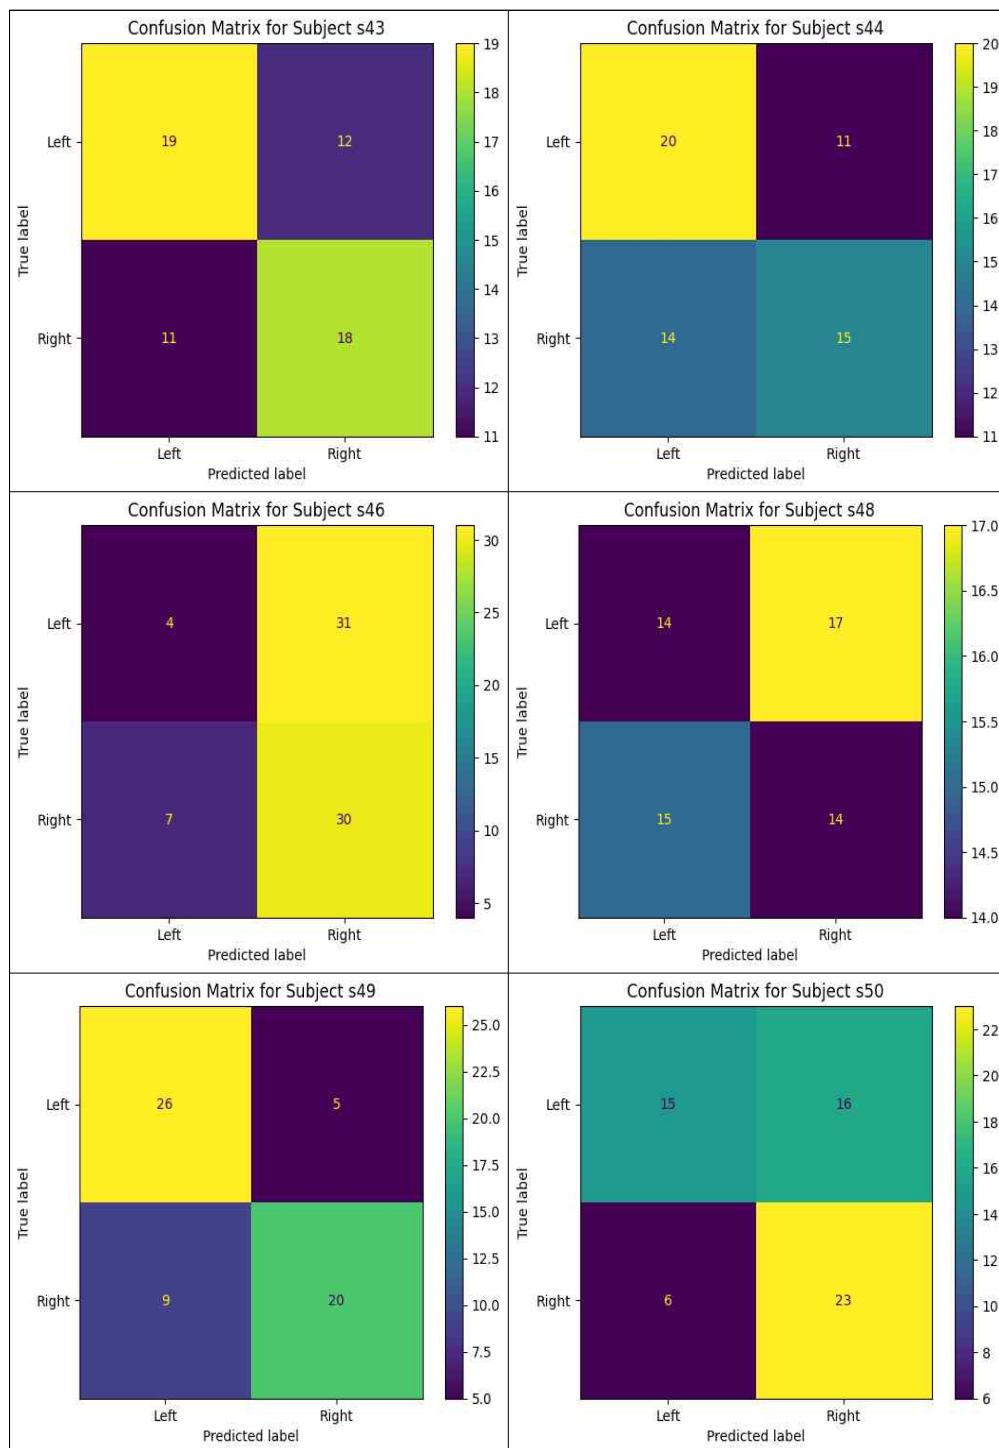


Fig 20. Confusion Matrix of individual dataset with CSP, SGD








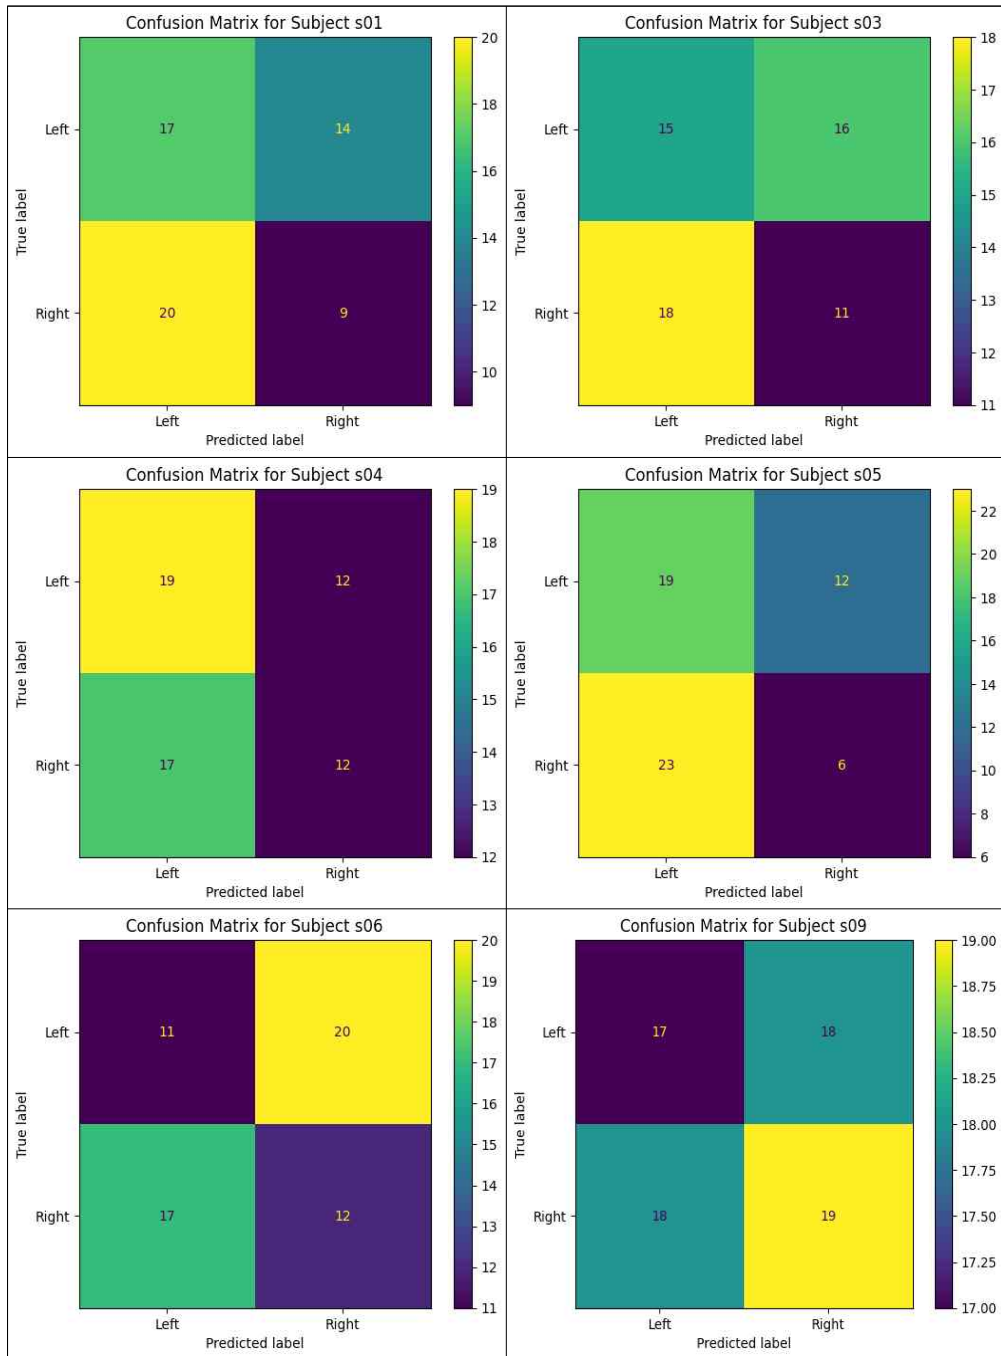
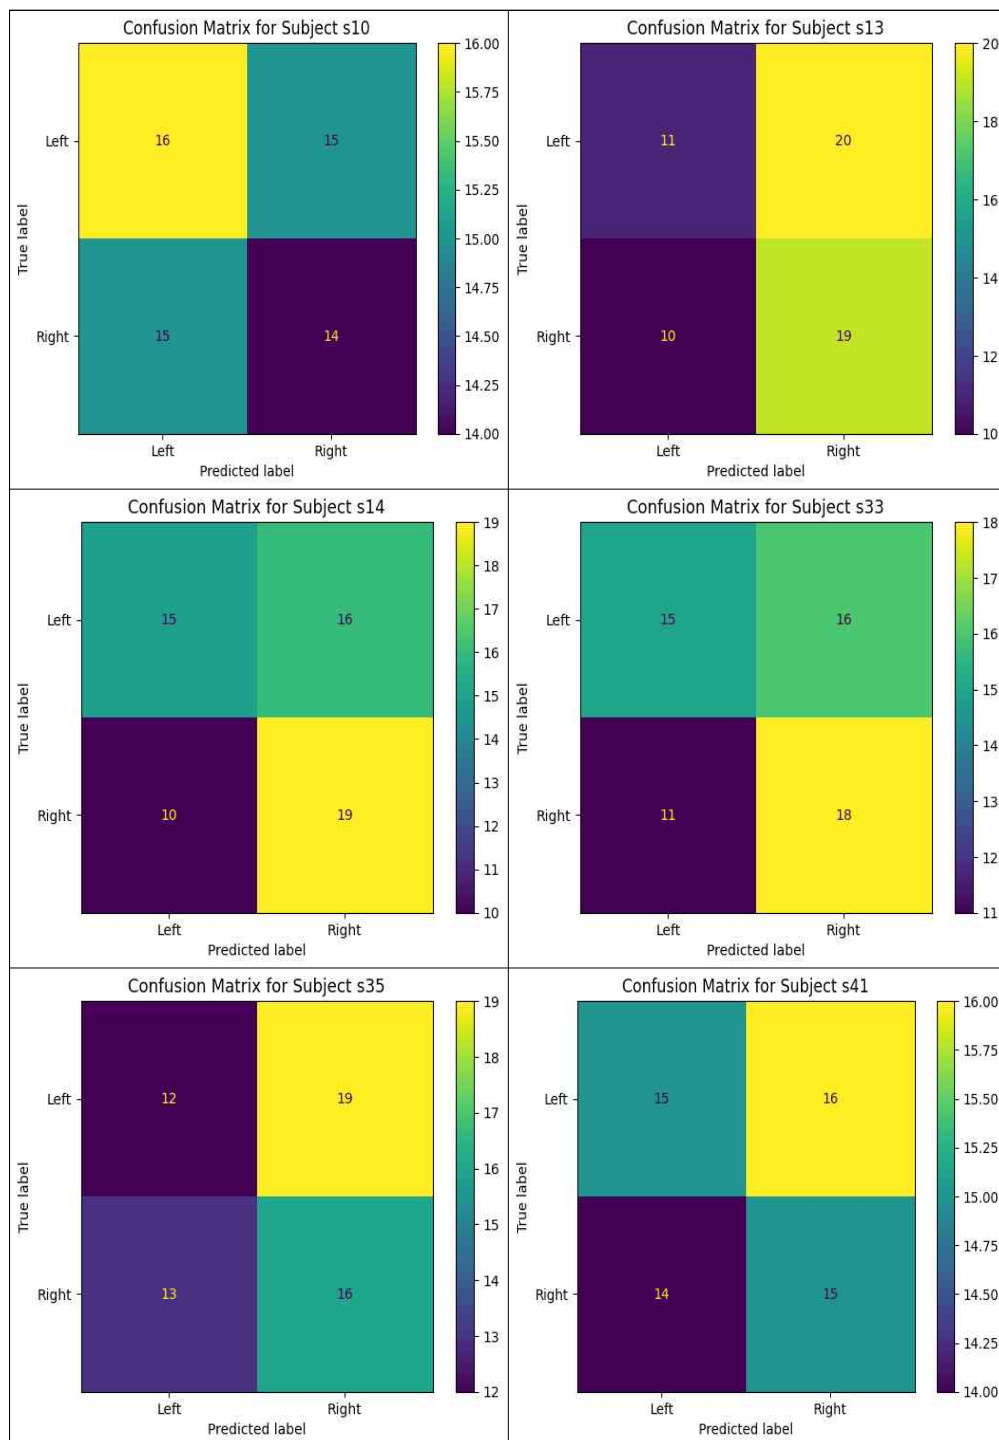
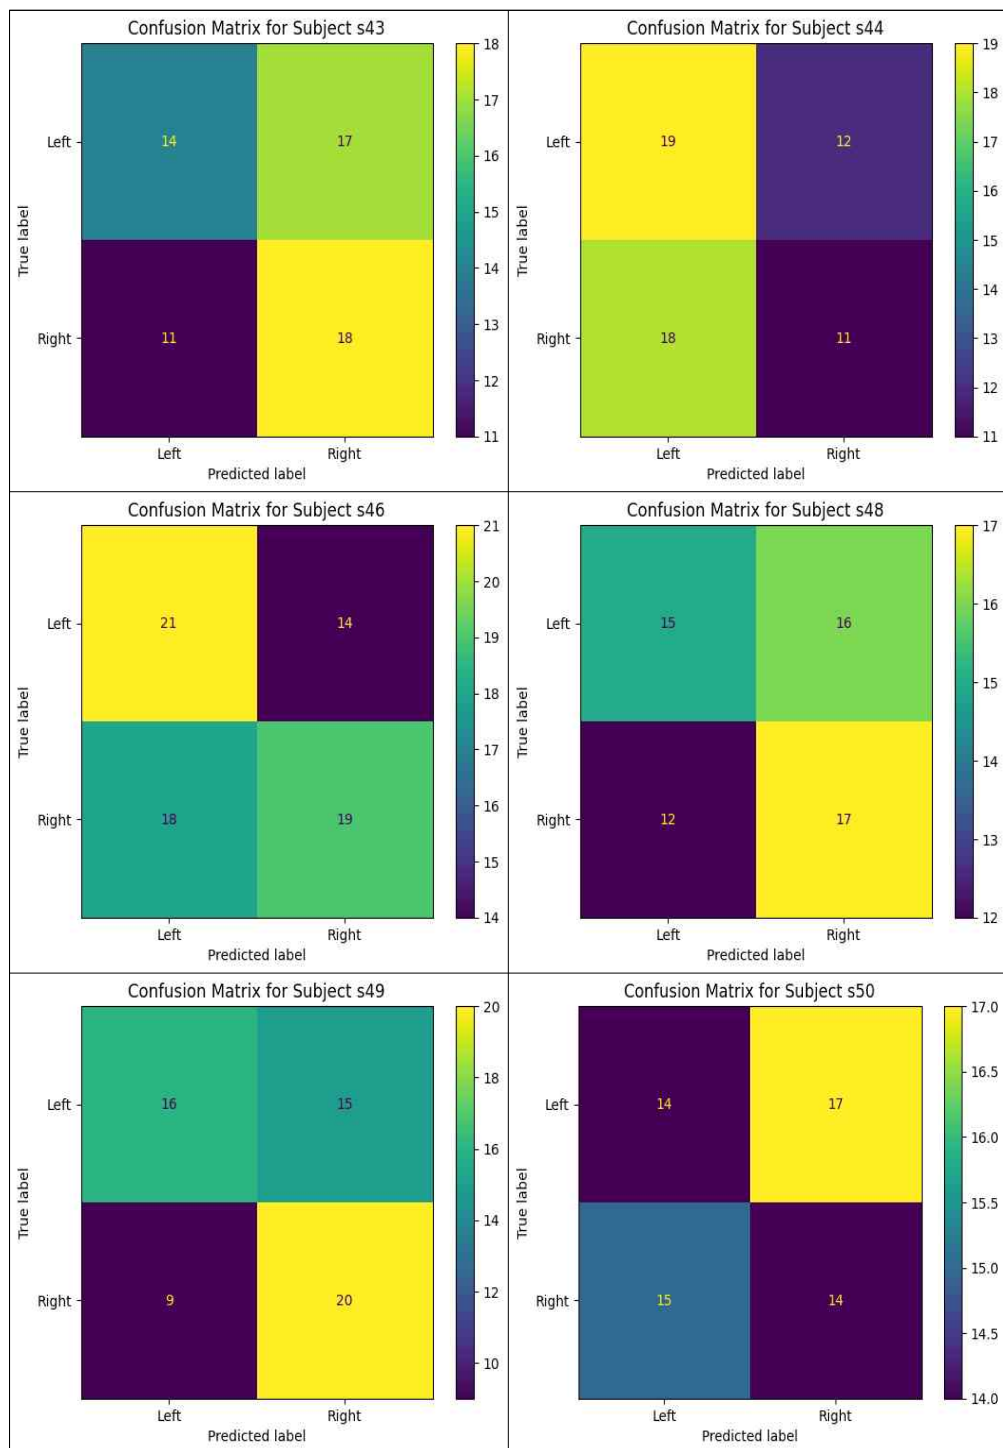


Fig 21. Confusion Matrix of individual dataset with CSP, MLP

3.2.2 Wavelet Transform 적용 결과








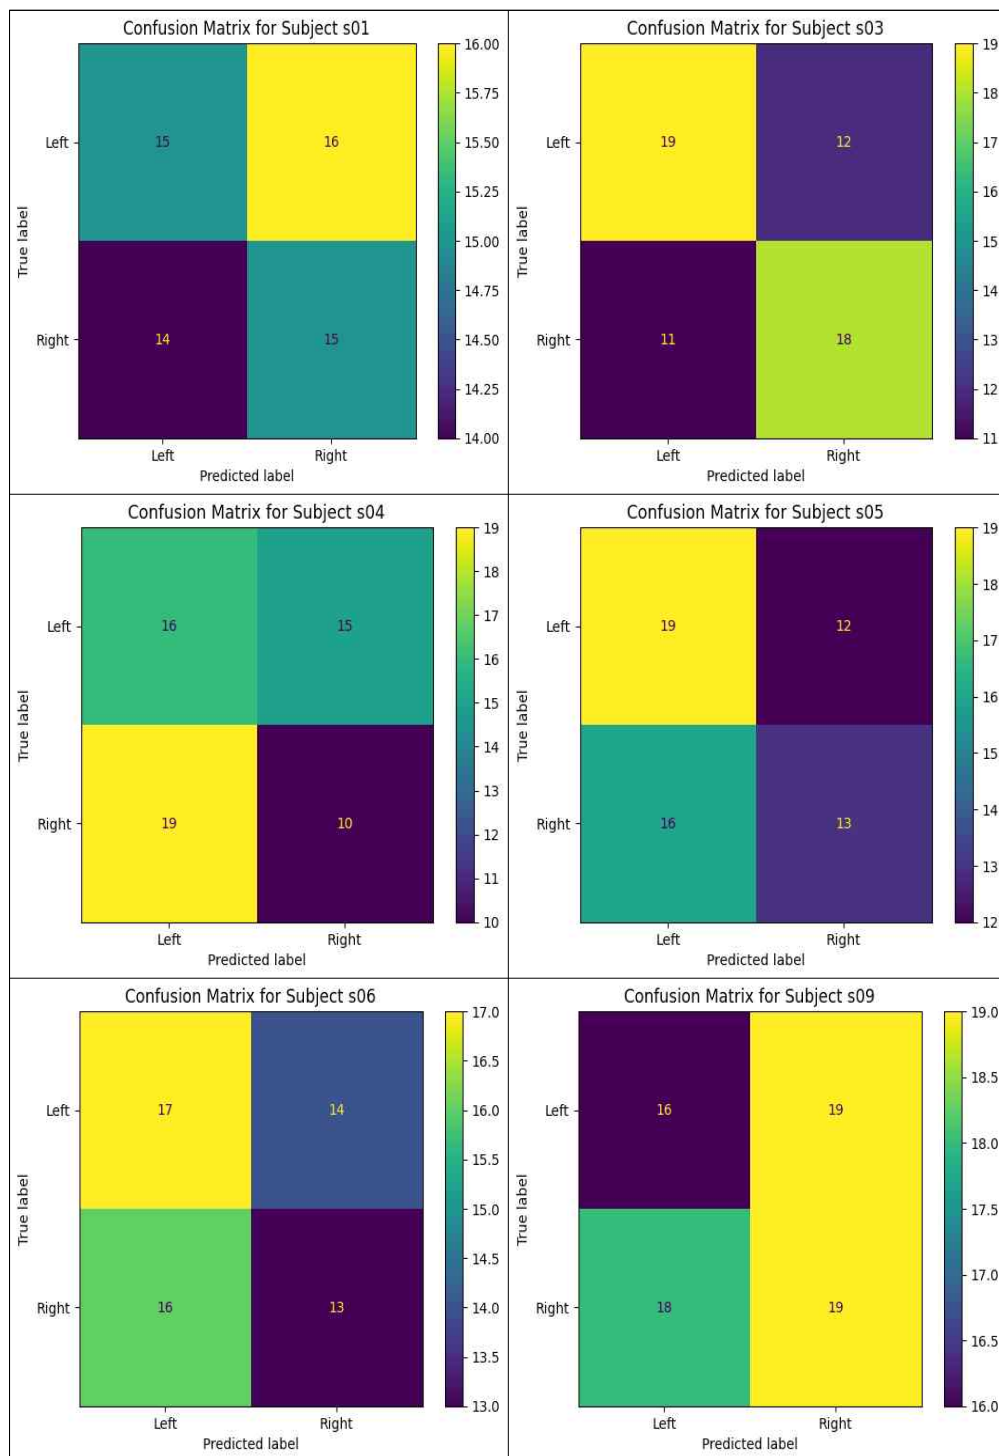
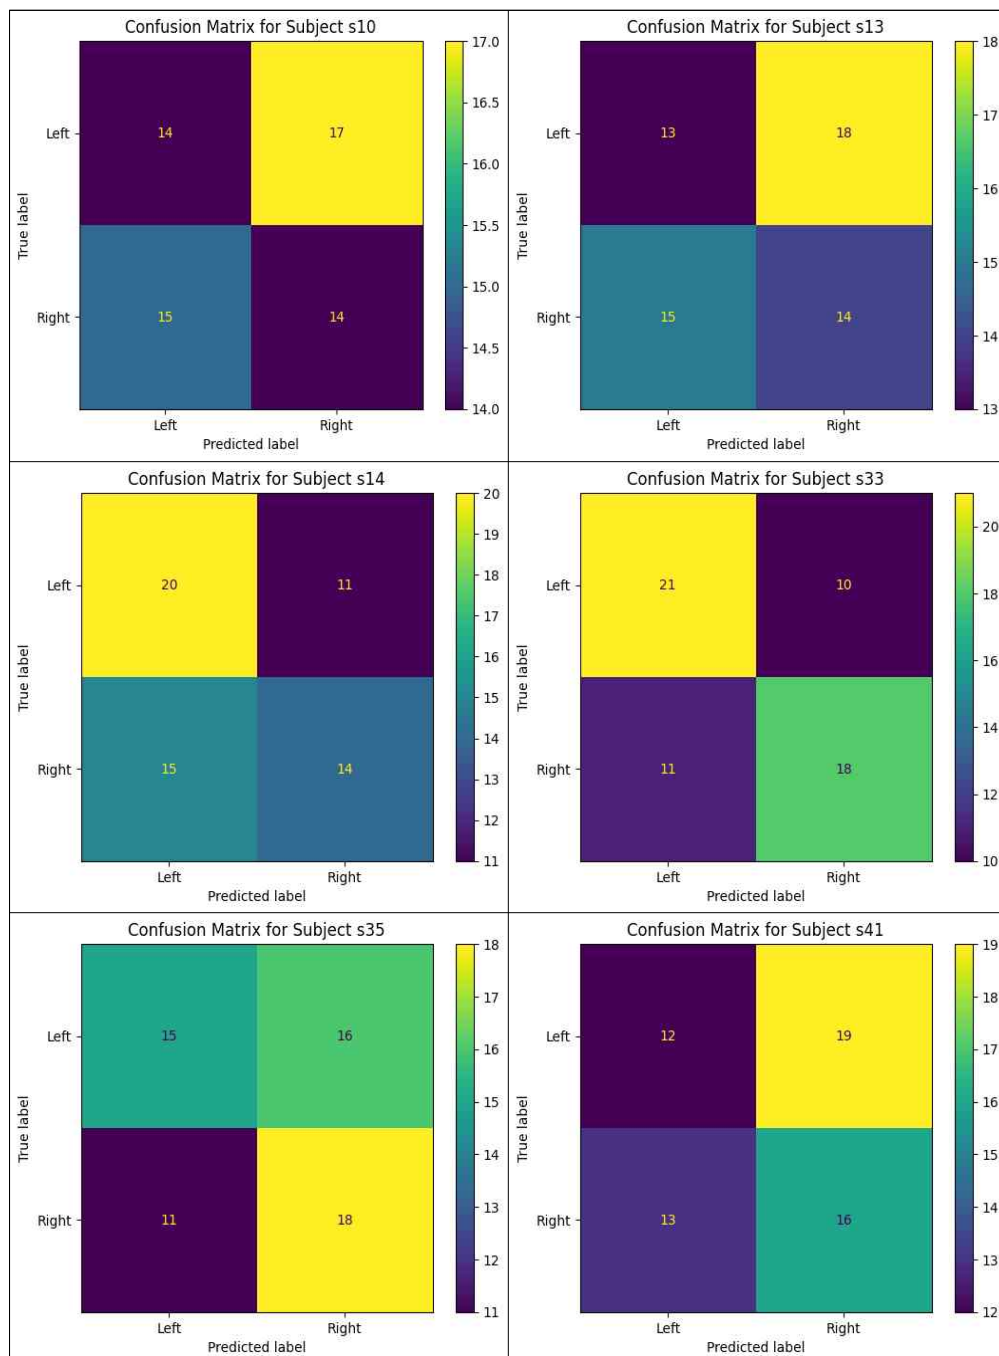
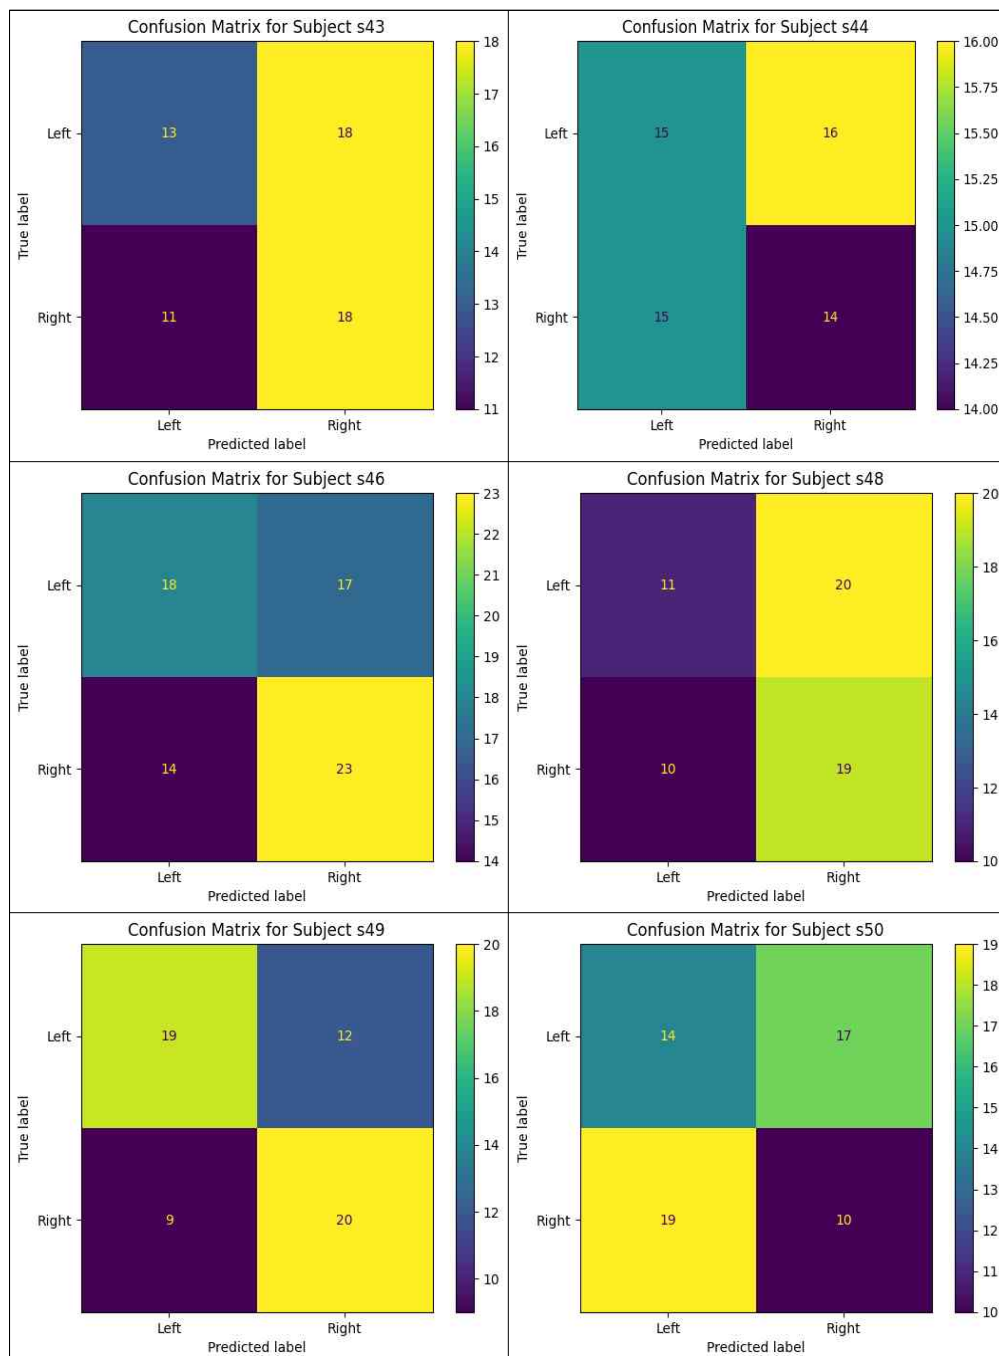


Fig 22. Confusion Matrix of individual dataset with Wavelet Transform, FLDA








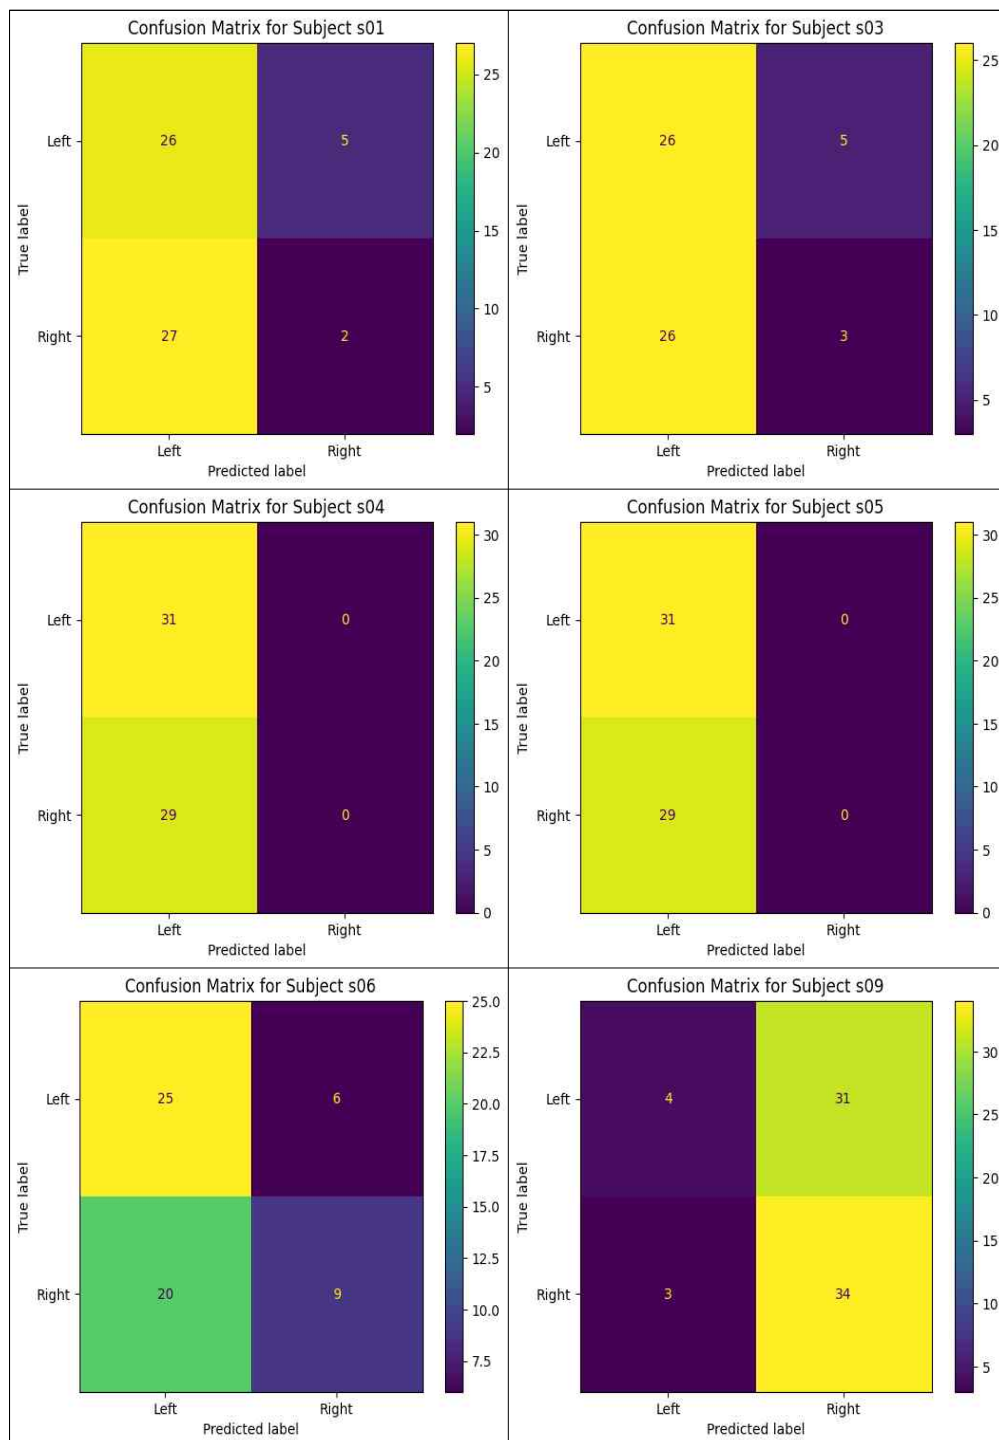
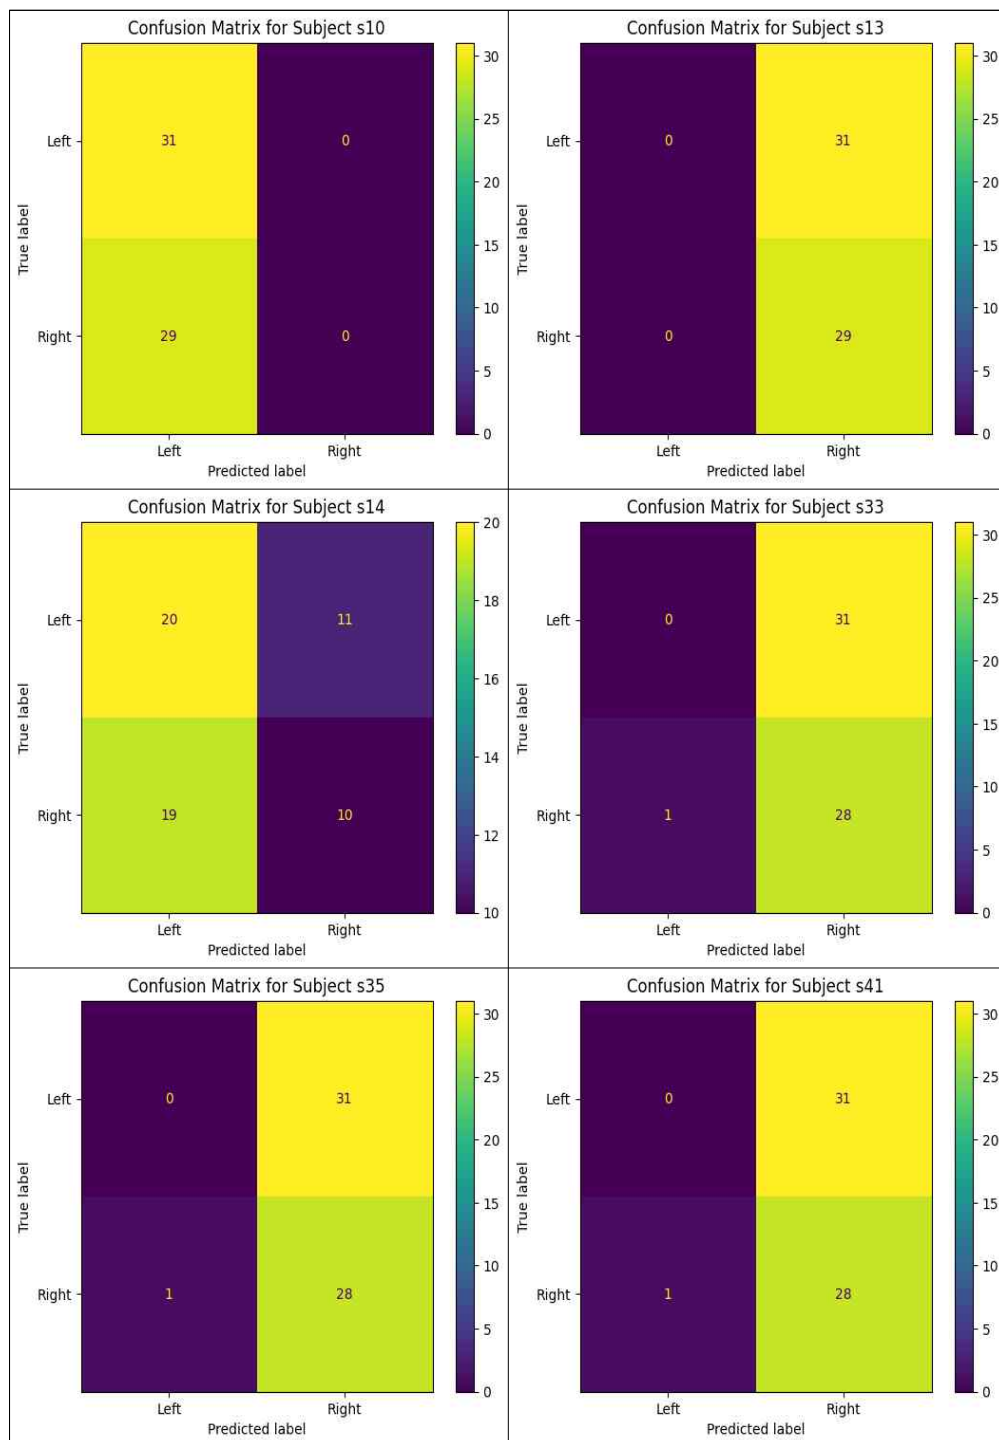
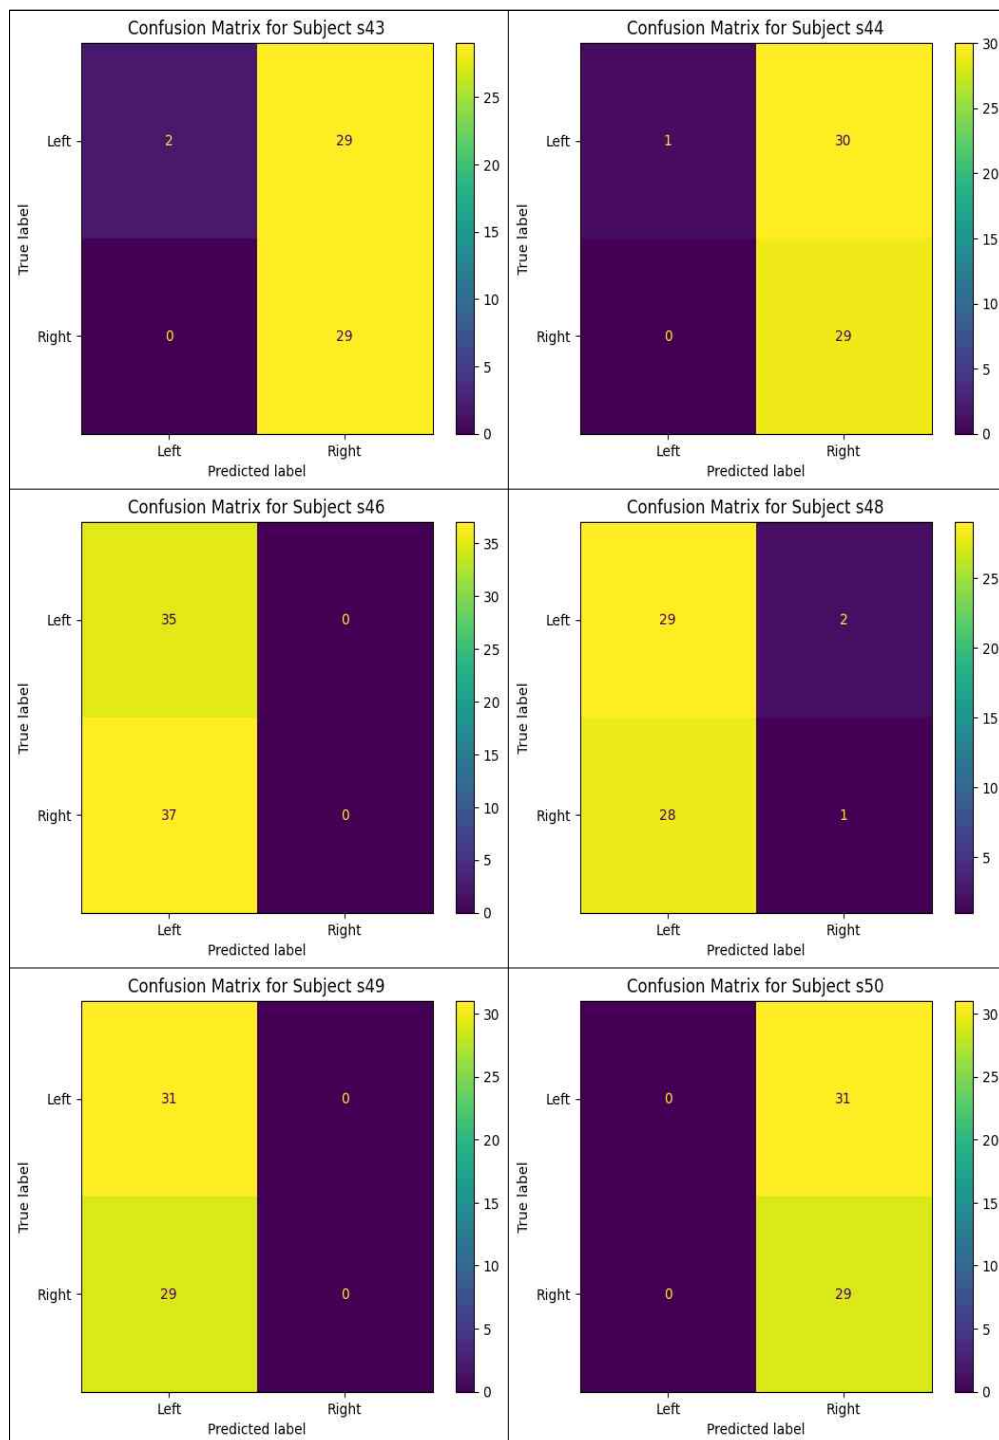


Fig 23. Confusion Matrix of individual dataset with Wavelet Transform, SVM








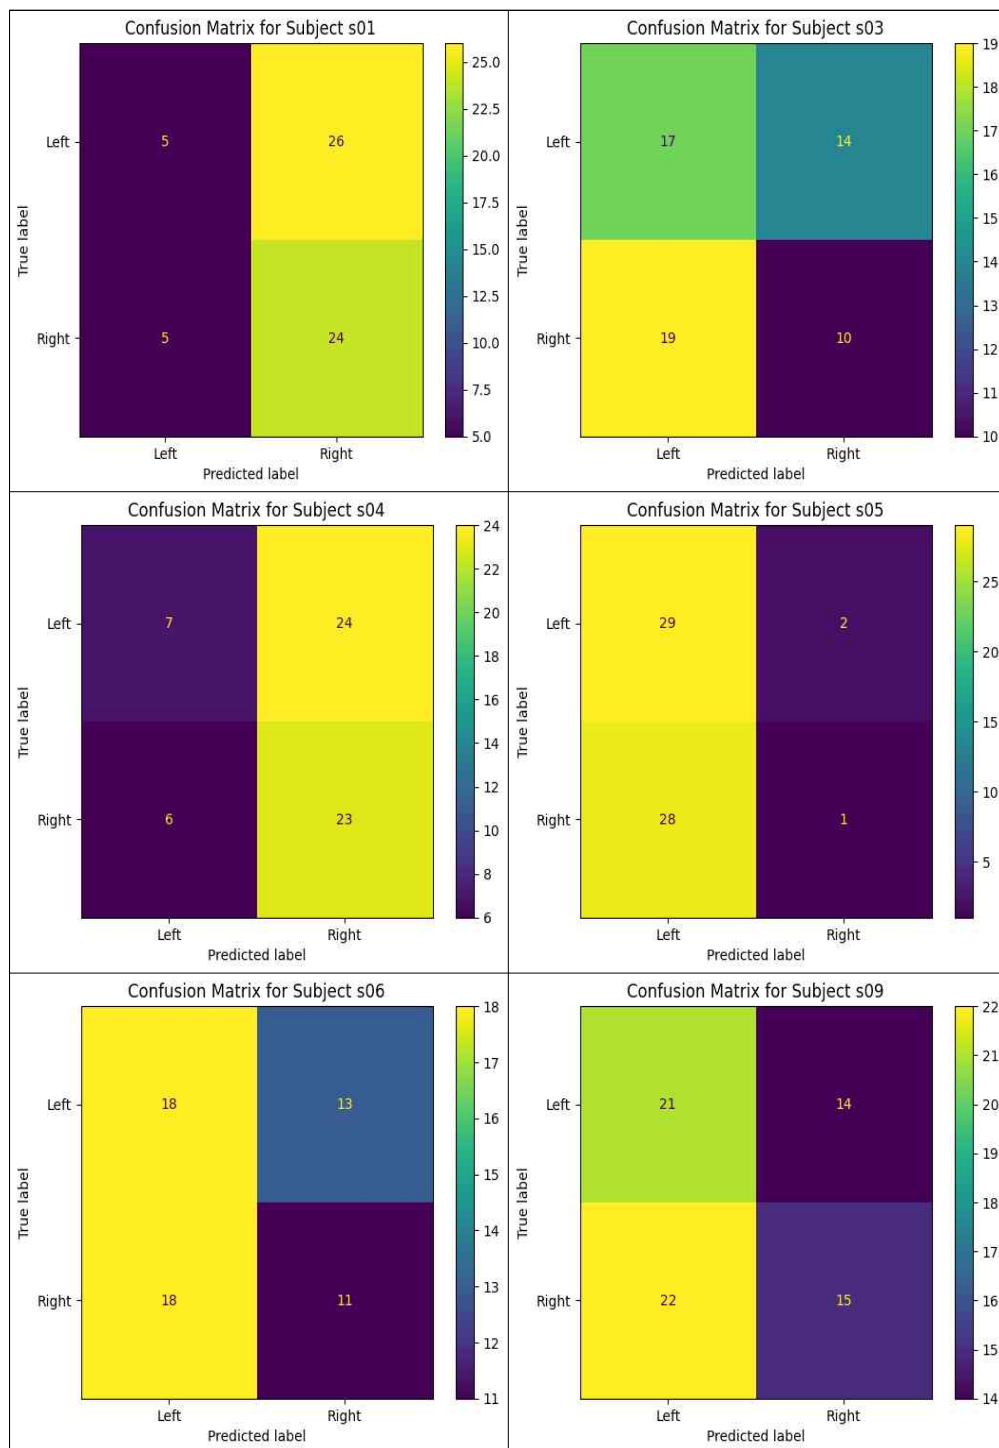
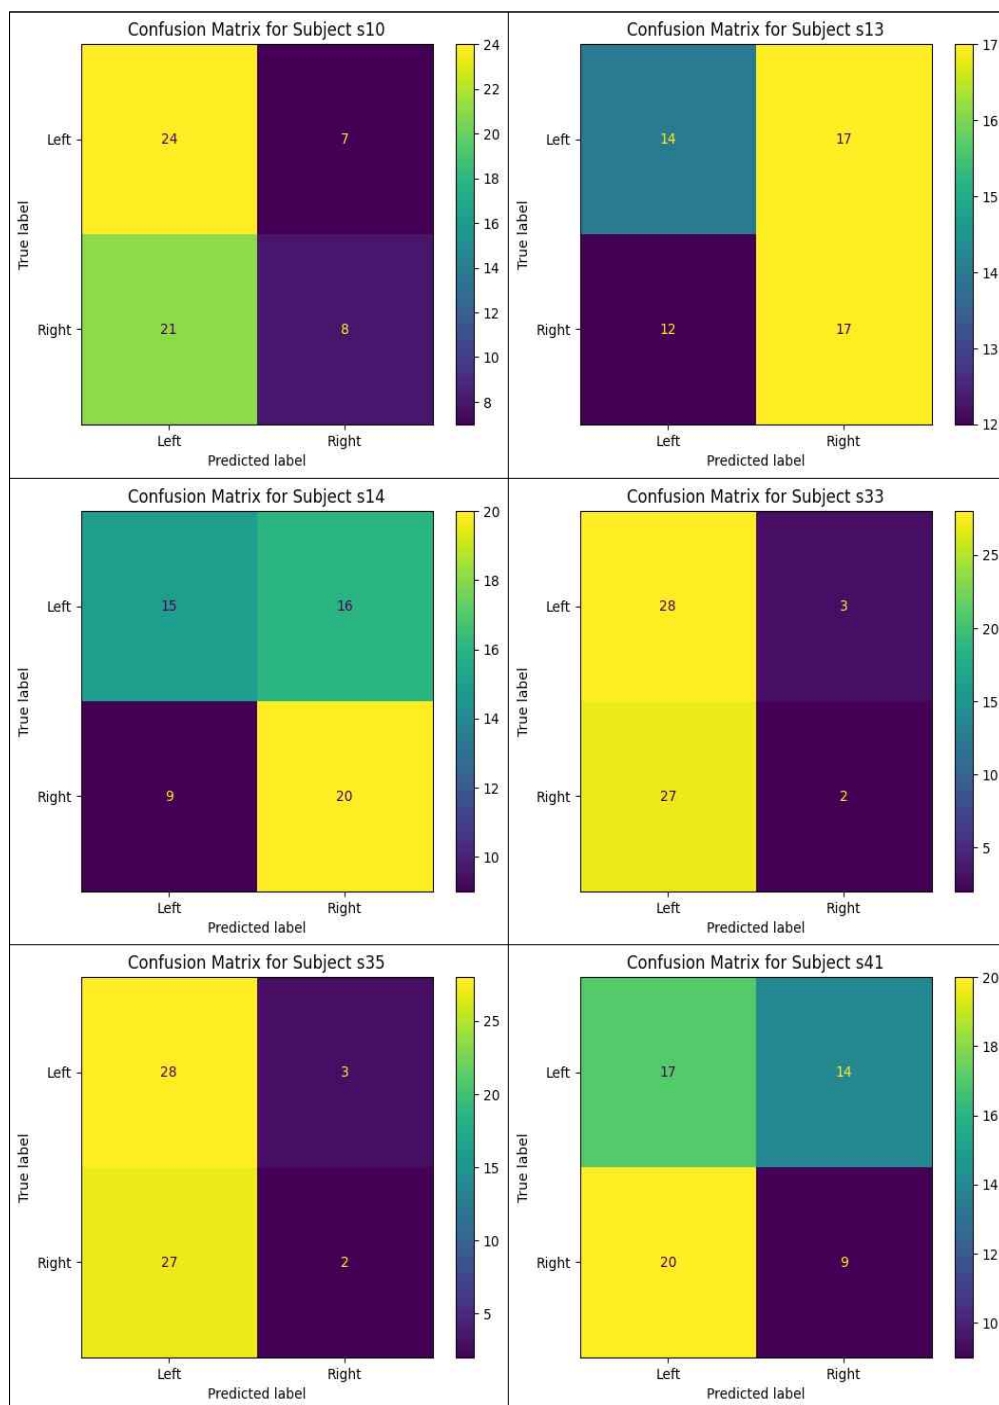
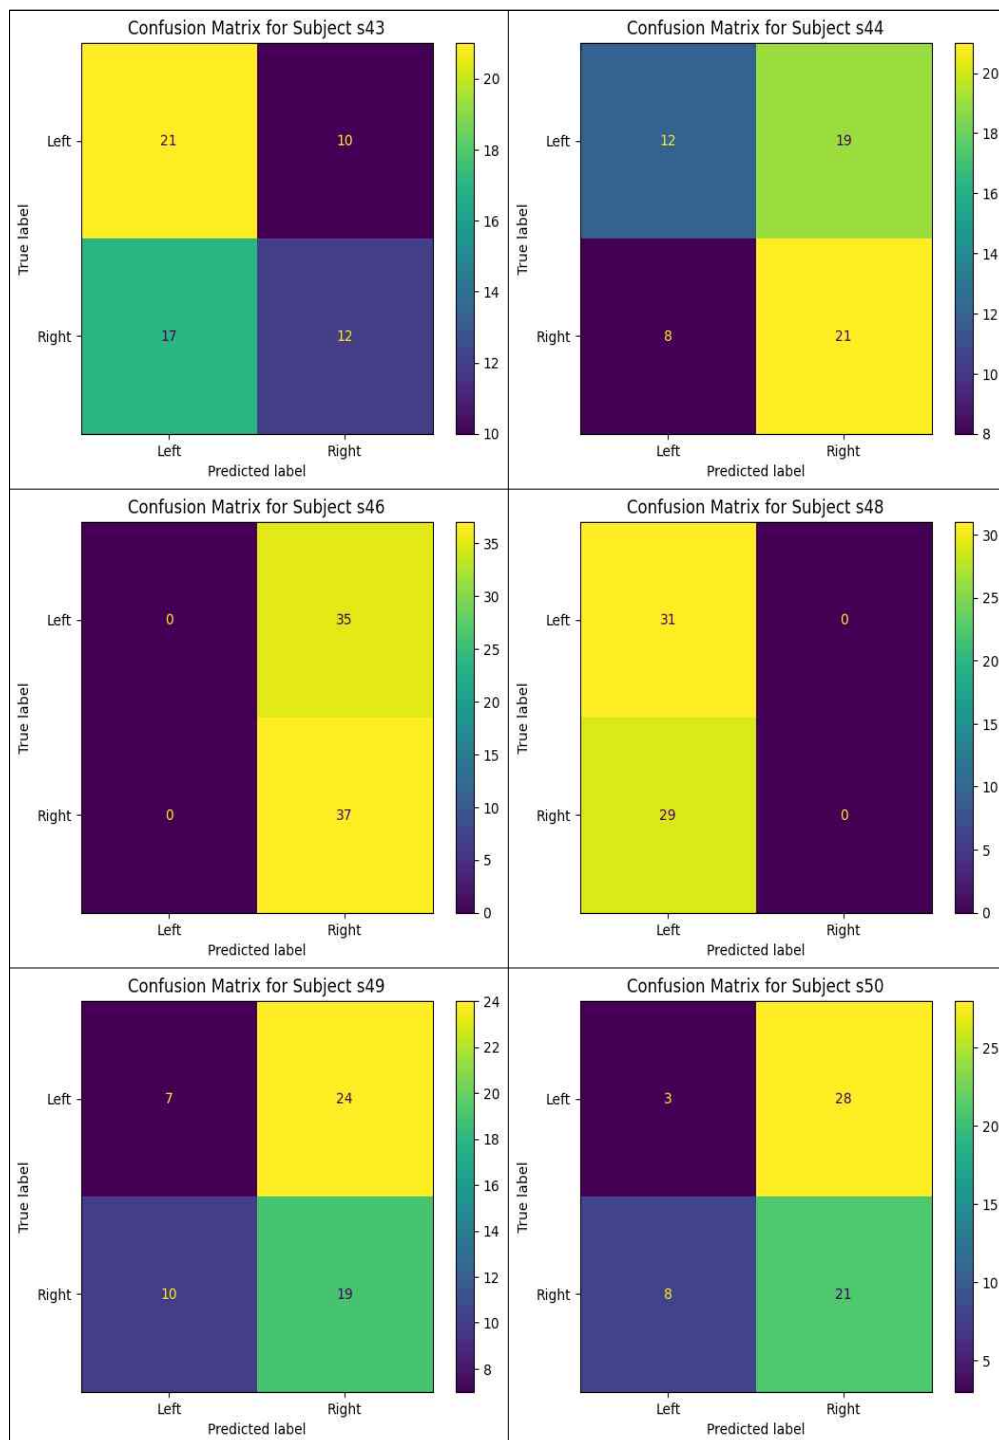


Fig 24. Confusion Matrix of individual dataset with Wavelet Transform, SGD










Fig 25. Confusion Matrix of individual dataset with Wavelet Transform, MLP

3.3 특징 추출기, 모델 조합에 따른 성능 평가

실험 결과 CSP를 사용한 경우, 각 분류 모델의 성능은 다음과 같다 (Table. 4). FLDA는 평균 57.54%, 최대 78.33%, SVM은 평균 58.54%, 최대 78.33%, SGD는 평균 53.13%, 최대 68.33%, MLP는 평균 58.25%, 최대 78.33% 분류 정확도를 달성하였다.

Wavelet Transform을 사용한 경우, 각 분류 모델의 성능은 다음과 같다 (Table. 5). FLDA는 평균 49.42%, 최대 60.00%, SVM은 평균 51.26%, 최대 65.00%, SGD는 평균 49.22%, 최대 56.67%, MLP는 평균 48.33%, 최대 58.33% 분류 정확도를 달성하였다.

Table 4. Subject Data Accuracy, f1-score with CSP, Multi Classification Model

| | FLDA | | SVM | | SGD | | MLP | |
|---------|----------------|----------|----------------|----------|----------------|----------|----------------|----------|
| subject | accuracy (%) | f1-score | accuracy (%) | f1-score | accuracy (%) | f1-score | accuracy (%) | f1-score |
| s1 | 76.67 | 0.76 | 75.00 | 0.74 | 50.00 | 0.35 | 78.33 | 0.78 |
| s3 | 61.67 | 0.61 | 56.67 | 0.55 | 48.33 | 0.34 | 58.33 | 0.57 |
| s4 | 63.33 | 0.63 | 63.33 | 0.63 | 53.33 | 0.39 | 60.00 | 0.60 |
| s5 | 68.33 | 0.68 | 70.00 | 0.70 | 68.33 | 0.67 | 70.00 | 0.70 |
| s6 | 60.00 | 0.59 | 61.67 | 0.61 | 51.67 | 0.35 | 60.00 | 0.59 |
| s9 | 47.22 | 0.44 | 47.22 | 0.40 | 50.00 | 0.42 | 47.22 | 0.42 |
| s10 | 58.33 | 0.58 | 53.33 | 0.48 | 50.00 | 0.34 | 50.00 | 0.38 |
| s13 | 70.00 | 0.69 | 66.67 | 0.67 | 55.00 | 0.45 | 68.33 | 0.68 |
| s14 | 63.33 | 0.63 | 61.67 | 0.61 | 53.33 | 0.49 | 61.67 | 0.62 |
| s33 | 53.33 | 0.53 | 60.00 | 0.59 | 68.33 | 0.67 | 65.00 | 0.65 |
| s35 | 38.33 | 0.38 | 43.33 | 0.42 | 50.00 | 0.35 | 41.67 | 0.41 |
| s41 | 51.67 | 0.51 | 51.67 | 0.50 | 51.67 | 0.52 | 50.00 | 0.48 |
| s43 | 58.33 | 0.58 | 60.00 | 0.60 | 60.00 | 0.59 | 61.67 | 0.62 |
| s44 | 56.67 | 0.57 | 56.67 | 0.56 | 48.33 | 0.31 | 58.33 | 0.58 |
| s46 | 50.00 | 0.50 | 51.39 | 0.50 | 51.39 | 0.37 | 47.22 | 0.40 |
| s48 | 48.33 | 0.48 | 55.00 | 0.52 | 48.33 | 0.39 | 46.67 | 0.47 |
| s49 | 78.33 | 0.78 | 78.33 | 0.78 | 61.67 | 0.57 | 76.67 | 0.77 |
| s50 | 63.33 | 0.63 | 65.00 | 0.64 | 55.00 | 0.49 | 63.33 | 0.63 |
| s52 | 41.67 | 0.42 | 41.67 | 0.41 | 45.00 | 0.43 | 40.00 | 0.40 |

Table 5. Subject Data Accuracy, f1-score with Wavelet Transform, Multi Classification Model

| | FLDA | | SVM | | SGD | | MLP | |
|---------|--------------|--------------|--------------|--------------|--------------|--------------|--------------|--------------|
| subject | accur acy | f1-sc ore | accur acy | f1-sc ore | accur acy | f1-sc ore | accur acy | f1-sc ore |
| s1 | 43.33 | 0.43 | 50.00 | 0.50 | 46.67 | 0.37 | 48.33 | 0.42 |
| s3 | 43.33 | 0.43 | 61.67 | 0.62 | 48.33 | 0.40 | 45.00 | 0.44 |
| s4 | 51.67 | 0.51 | 43.33 | 0.43 | 51.67 | 0.35 | 50.00 | 0.46 |
| s5 | 41.67 | 0.39 | 53.33 | 0.53 | 51.67 | 0.35 | 50.00 | 0.37 |
| s6 | 38.33 | 0.38 | 50.00 | 0.50 | 56.67 | 0.54 | 48.33 | 0.48 |
| s9 | 50.00 | 0.50 | 48.61 | 0.49 | 52.78 | 0.44 | 50.00 | 0.50 |
| s10 | 50.00 | 0.50 | 46.67 | 0.47 | 51.67 | 0.35 | 53.33 | 0.50 |
| s13 | 50.00 | 0.49 | 45.00 | 0.45 | 48.33 | 0.31 | 51.67 | 0.51 |
| s14 | 56.67 | 0.56 | 56.67 | 0.56 | 50.00 | 0.49 | 58.33 | 0.58 |
| s33 | 55.00 | 0.55 | 65.00 | 0.65 | 46.67 | 0.31 | 50.00 | 0.39 |
| s35 | 46.67 | 0.46 | 55.00 | 0.55 | 46.67 | 0.31 | 50.00 | 0.39 |
| s41 | 50.00 | 0.50 | 46.67 | 0.46 | 46.67 | 0.31 | 43.33 | 0.43 |
| s43 | 53.33 | 0.53 | 51.67 | 0.51 | 51.67 | 0.38 | 55.00 | 0.54 |
| s44 | 50.00 | 0.49 | 48.33 | 0.48 | 50.00 | 0.35 | 55.00 | 0.54 |
| s46 | 55.56 | 0.55 | 56.94 | 0.57 | 48.61 | 0.32 | 51.39 | 0.35 |
| s48 | 53.33 | 0.53 | 50.00 | 0.49 | 50.00 | 0.37 | 51.67 | 0.35 |
| s49 | 60.00 | 0.60 | 65.00 | 0.65 | 51.67 | 0.35 | 43.33 | 0.41 |
| s50 | 46.67 | 0.47 | 40.00 | 0.40 | 48.33 | 0.31 | 40.00 | 0.33 |
| s52 | 45.00 | 0.44 | 40.00 | 0.40 | 51.67 | 0.47 | 45.00 | 0.43 |

IV. 토의

4.1 결론

본 연구에서는 뇌파 데이터를 바탕으로 기계학습을 사용하여 분류 기능을 수행하는 연구를 구현하였다. 본 연구 과정은 다음과 같다.

첫 번째로, Motor Imagery 데이터를 수집하였다. EEG/EMG 데이터를 수집하기 위해 The Biosemi ActiveTwo System, BCI2000 system 3.0.2를 사용하였으며, 각 피험자의 Trial Data를 수집하였다. 측정된 데이터는 Imagery Data 100 또는 120개, movement Data 20개를 수집했다.

두 번째로, 수집된 데이터를 EEG/EMG로 분류한 후, 데이터의 품질을 검사하는 Bad Trial 검사를 수행했다. Bad Trial은 노이즈(눈 깜빡임, 턱 움직임, 머리 움직임)가 많거나, 뇌파 측정 오류가 포함된 데이터를 의미한다. 이러한 데이터는 분류 모델 성능에 부정적인 영향을 미칠 수 있으므로, 모든 Trial 데이터를 검사하여 Bad Trial 데이터를 제거하였다. 전처리 과정 및 데이터 검사에서 모든 데이터가 유효하다는 것을 확인하였다.

세 번째로, 특징 추출 방법을 사용하여, 각 데이터 내 고유 특징을 추출하였다. 이는 모델이 데이터를 효과적으로 학습하고 구별할 수 있도록 하기 위함이다. 본 연구에서는 Left/Right를 클래스로 설정하였고, 특징 추출 방법으로 Common Spatial Pattern(CSP), Wavelet Transform을 사용했다. 모두 각각 EEG와 같은 다채널 구조와 비선형적 데이터에 적합한 방법으로 알려져있다 [19, 31]. CSP는 2차원 공간(Spatial)을 설정하여 특징을 추출하였고, Wavelet Transform는 레벨 3으로 설정하여 특징을 추출했다.

네 번째로, 추출된 특징 데이터를 바탕으로 분류 모델을 적용하였다. 사용된 분류 모델은 Fisher's Linear Discriminant Analysis(FLDA), Support Vector Machine(SVM), Stochastic Gradient Descent(SGD), Multi-Layer Perceptron(MLP)이다. LDA 모델은 이전 연구에서 사용한 방법이 존재한다 [32, 33, 34]. 그 중 하나는 80%의 정확도를 달성했다 [34]. FLDA는 두 개의 클래스를 구별하는 데 최적화된 기법으로, 본 연구에서는 평균 60%, 최대 78%의 분류 정확도를 달성하였다(Table 4). 또한, 다른 모델들의 분류 성능도 분석하여 결과를 도출하였다(Table 4, 5).

본 연구의 결과는 다음과 같은 시사점을 제공한다. 일반적으로 기계학습은 이미지와 같은 선형적인 데이터를 처리하는 데 적합하다고 여기지만, 뇌파와 같은 비선형적 시간 기반 데이터에도 적용할 수 있다는 것을 확인하였다. 이러한 데이터는 의료 분야에서 질병 진단과 같은 실제 응용에 사용될 수 있다.

또한, 비선형 데이터를 분류하기 위해 각 데이터만의 특징을 추출하는 방법을 사용했으며, 본 연구에서는 Common Spatial Pattern(CSP), Wavelet Transform을 사용하여 데이터의 고유 특성을 도출할 수 있었다.

또한 단일 모델뿐만 아니라, FLDA, SVM, SGD, MLP와 같은 다양한 모델을 적용하여 성능을 분석하였다.

마지막으로, 데이터 필터링을 통해 데이터 품질을 향상시켰다. Band-Pass Filtering, Butterworth Filtering, High-Pass Filtering를 사용하여 데이터 내에 있는 노이즈를 최대한 제거하고, 모델의 성능을 향상시켰다.

4.2 연구의 한계점

본 연구에서는 다음의 한계점이 존재한다.

첫 번째로 낮은 분류 정확도이다. 3.3 성능 평가에서 알 수 있듯이, 적용된 각 모델의 분류 정확도는 대부분 40~50% 수준에 머물렀다. 이는 데이터 내 노이즈가 여전히 존재하는 것이 원인으로 볼 수 있다. 본 연구에서는 Band-Pass, Butterworth, High-Pass Filtering 기법을 사용했음에도 불구하고, 데이터 내 노이즈 제거가 충분히 이루어지지 않은 것으로 판단된다. 또한 Common Spatial Pattern(CSP), Wavelet Transform을 특징 추출 방법으로 사용하였으며, 향후 연구에서는 Independent Component Analysis(ICA)와 같은 기법을 추가적으로 적용할 예정이다. ICA는 뇌파 데이터에서 눈 깜빡임, 눈 움직임 등 노이즈를 제거하는데 효과적인 방법으로 알려져 있으며, EEGLAB에서도 사용하는 방법이다 [36, 37].

두 번째로, 분류 모델의 낮은 성능이다. 3.3 성능 평가에서 FLDA, SVM, SGD, MLP 모델 모두에서 40~50%의 분류 정확도를 보였다. 이를 개선하기 위해, 향후 연구에서는 XGBoost, Random Forest와 같은 다른 모델을 적용할 예정이다. 또한, Spiking Neural Network(SNN)도 함께 적용할 예정이다.

SNN이란, 인공신경망(Artificial Neural Network, ANN)의 한 종류로, 주로 시간적 신호와 이벤트 기반 처리를 통해 정보를 처리한다. SNN은 뉴런 간의 스파이크(Spike)를 주요 정보 단위로 사용하며, 생물학적 뉴런의 동작 방식을 더 잘 반영하는 특징이 있다. SNN을 구현할 수 있는 라이브러리는 Spyx, snntorch 등 다양하게 있으며, 이를 활용해 실제 SNN을 구현할 수 있다. SNN을 사용한 이전 연구에서는 본 연구와 유사한 분류 기능 및 디코딩 작업을 구현한 사례가 존재한다 [39, 40]. 향후 연구에서는 snntorch를 사용하여 분류 기능을 구현할 예정이다 [38]. 이를 통해 본 연구보다 더 나은 성능을 달성할 수 있기를 기대해볼 수 있다.

Reference

- [1] H. Cho, M. Ahn, S. Ahn, M. Kwon, and S. C. Jun, "EEG datasets for motor imagery brain-computer interface," *GigaScience*, vol. 6, no. 7, pp. 1-8, 2017.
- [2] G. Schalk, D. J. McFarland, T. Hinterberger, N. Birbaumer, and J. R. Wolpaw, "BCI2000: a general-purpose brain-computer interface (BCI) system," *IEEE Transactions on biomedical engineering*, vol. 51, no. 6, pp. 1034-1043, 2004.
- [3] M. Tervaniemi, "The neuroscience of music - towards ecological validity," *Trends in Neurosciences*, vol. 46, no. 5, pp. 355-364, 2023.
- [4] X. Gu et al., "EEG-based brain-computer interfaces (BCIs): A survey of recent studies on signal sensing technologies and computational intelligence approaches and their applications," *IEEE/ACM transactions on computational biology and bioinformatics*, vol. 18, no. 5, pp. 1645-1666, 2021.
- [5] Muller-Putz G, Scherer R, Brunner C et al. Better than random: a closer look on BCI results. *Int J Bioelectromagn* 2008;10:52 - 5.
- [6] Muthukumaraswamy S. High-frequency brain activity and muscle artifacts in MEG/EEG: a review and recommendations. *Front Hum Neurosci* 2013;7:138.
- [7] van Dinteren R, ArnsM, Jongsma ML et al. P300 development across the lifespan: a systematic
- [8] Pfurtscheller G, Lopes da Silva FH. Event-related EEG/MEG synchronization and desynchronization: basic principles. *Clin*

Neurophysiol 1999;110:1842 - 57.

[9] Grosse-Wentrup M, Schölkopf B. A review of performance variations in SMR-based brain-computer interfaces (BCIs). In: Guger C, Allison BZ, Edlinger G, eds. Brain - Computer Interface Research. New York: Springer; 2013:39 - 51. http://link.springer.com/chapter/10.1007/978-3-642-36083-1_5 (21 December 2016, date last accessed).

[10] Blankertz B, Sannelli C, Halder S et al. Neurophysiological predictor of SMR-based BCI performance. Neuroimage 2010;51:1303 - 9.

[11] Ahn M, Cho H, Ahn S et al. High theta and low alpha powers may be indicative of BCI-Illiteracy in motor imagery. PLoS One 2013;8:e80886.

[12] Cho H, Ahn M, Kim K et al. Increasing session-to-session transfer in a brain - computer interface with on-site background noise acquisition. J Neural Eng 2015;12:66009.

[13] Cho H, Ahn M, Ahn S et al. Supporting data for "EEG datasets for motor imagery brain computer interface." GigaScience Database 2017; <http://dx.doi.org/10.5524/100295>.

[14] A. Bablani, D. R. Edla, V. Kuppili, and D. Ramesh, "A multi stage EEG data classification using k-means and feed forward neural network," *Clinical Epidemiology and Global Health*, vol. 8, no. 3, pp. 718-724, 2020.

[15] D. Gutiérrez and D. I. Escalona-Vargas, "EEG data classification through signal spatial redistribution and optimized linear discriminants,"

Computer methods and programs in biomedicine, vol. 97, no. 1, pp. 39–47, 2010.

[16] Z. Jiao, X. Gao, Y. Wang, J. Li, and H. Xu, "Deep convolutional neural networks for mental load classification based on EEG data," *Pattern Recognition*, vol. 76, pp. 582–595, 2018.

[17] BCI2000 wiki. www.bci2000.org (15 April 2017, date last accessed).

[18] The Biosemi ActiveTwo System wiki.
https://www.biosemi.com/Products_ActiveTwo.html

[19] Ramoser H, Muller-Gerking J, Pfurtscheller G. Optimal spatial filtering of single trial EEG during imagined hand movement. *IEEE Trans Rehabil Eng* 2000;8:441 - 6.

[20] Blankertz B, Tomioka R, Lemm S et al. Optimizing spatial filters for robust EEG single-trial analysis. *IEEE Signal Process Mag* 2008;25:41 - 56.

[21] Vaughan TM, Miner LA, McFarland DJ et al. EEG-based communication: analysis of concurrent EMG activity. *Electroencephalogr Clin Neurophysiol* 1998;107:428 - 33.

[22] electronics tutorials Passive Band Pass Filter.
https://www.electronics-tutorials.ws/filter/filter_4.html

[23] electronics tutorials Passive High Pass Filter.
https://www.electronics-tutorials.ws/filter/filter_3.html

[24] K. A. Ludwig, R. M. Miriani, N. B. Langhals, M. D. Joseph, D. J.

Anderson, and D. R. Kipke, "Using a common average reference to improve cortical neuron recordings from microelectrode arrays," *Journal of neurophysiology*, vol. 101, no. 3, pp. 1679–1689, 2009.

[25] GUI Common Average Reference
<https://open-ephys.github.io/gui-docs/User-Manual/Plugins/Common-Average-Reference.html>

[26] C. S. Burrus, R. A. Gopinath, and H. Guo, "Wavelets and wavelet transforms," *rice university, houston edition*, vol. 98, 1998.

[27] M. Farge, "Wavelet transforms and their applications to turbulence," *Annual review of fluid mechanics*, vol. 24, no. 1, pp. 395–458, 1992.

[28] PyWavelets Documentation PyWavelets – Wavelet Transforms in Python. <https://pywavelets.readthedocs.io/en/latest/>

[29] 정보통신기술용어해설 Butterworth Filter http://www.ktword.co.kr/test/view/view.php?m_temp1=4066&id=790

[30] electronics tutorials Butterworth Filter Design
https://www.electronics-tutorials.ws/filter/filter_8.html

[31] B. Blankertz, R. Tomioka, S. Lemm, M. Kawanabe, and K.-R. Müller, "Optimizing spatial filters for robust EEG single-trial analysis," *IEEE Signal Process. Mag.*, vol. 25, no. 1, pp. 41 – 56, Jan. 2008.

[32] F. Lotte, "A tutorial on EEG signal-processing techniques for mental-state recognition in brain - computer interfaces," in *Guide to Brain-Computer Music Interfacing*. London, U.K.: Springer, 2014, pp. 133

- 161.

[33] F. Lotte, M. Congedo, A. Lécuyer, F. Lamarche, and B. Arnaldi, "A review of classification algorithms for EEG-based brain - computer interfaces," *J. Neural Eng.*, vol. 4, no. 2, p. R1, 2007.

[34] P. Gaur, H. Gupta, A. Chowdhury, K. McCreadie, R. B. Pachori, and H. Wang, "A sliding window common spatial pattern for enhancing motor imagery classification in EEG-BCI," *IEEE Transactions on Instrumentation and Measurement*, vol. 70, pp. 1–9, 2021.

[35] P. S. Maciag, W. Sitek, Ł. Skonieczny, and H. Rybiński, "A comparative study of short text classification with spiking neural networks," in *2022 17th Conference on Computer Science and Intelligence Systems (FedCSIS)*, 2022: IEEE, pp. 79–88.

[36] EEGLAB Wiki - Independent Component Analysis for artifact removal. https://eeglab.org/tutorials/06_RejectArtifacts/RunICA.html

[37] A. Delorme and S. Makeig, "EEGLAB: an open source toolbox for analysis of single-trial EEG dynamics including independent component analysis," *Journal of neuroscience methods*, vol. 134, no. 1, pp. 9–21, 2004.

[38] J. Eshraghian *et al.*, "Training spiking neural networks using lessons from deep learning. arXiv," *arXiv preprint arXiv:2109.12894*, 2021.

[39] K. Kumarasinghe, N. Kasabov, and D. Taylor, "Brain-inspired spiking neural networks for decoding and understanding muscle activity and kinematics from electroencephalography signals during hand

movements," *Scientific reports*, vol. 11, no. 1, p. 2486, 2021.

[40] P. S. Maciag, W. Sitek, Ł. Skonieczny, and H. Rybiński, "A comparative study of short text classification with spiking neural networks," in *2022 17th Conference on Computer Science and Intelligence Systems (FedCSIS)*, 2022: IEEE, pp. 79–88.